

Giới thiệu (Introduction)

Xử Lý Ngôn Ngữ Tự Nhiên
(Natural Language Processing - NLP)
Vũ Đình Khôi

Nội dung

- Giới thiệu chung
- Các mức phân tích trong Xử lý ngôn ngữ tự nhiên
- Các ứng dụng của Xử lý ngôn ngữ tự nhiên

- [1] Chapter 1, 2. Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta, and Harshit Surana, *Practical Natural Language Processing*. O'Reilly, 2020.
- [2] Chapter 1. Jay Alammam and Maarten Grootendorst, *Hands-On Large Language Models*. O'Reilly, 2024.
- [3] Chapter 1. Suhas Pai, *Designing Large Language Model Applications*. O'Reilly, 2025.
- [4] Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
 - <https://web.stanford.edu/~jurafsky/slp3/>

I find that I don't understand things unless I try to program them.




Donald E. Knuth

Professor Emeritus at Stanford University

If you want to **master something**, teach it




-- **Richard Feynman**



A language is not just words. It's a culture, a tradition,
a unification of a community,
a whole history that creates what a community is.
It's all embodied in a language.
—Noam Chomsky

- Xử lý ngôn ngữ tự nhiên(Natural Language Processing – NLP)
 - Lĩnh vực của khoa học máy tính chuyên nghiên cứu các phương pháp phân tích, mô hình hóa (**model**) và hiểu ngôn ngữ con người (**human language**).

■ Các nhiệm vụ (**tasks**) và ứng dụng (**applications**) của NLP



■ Các ứng dụng chính (core applications)

- Email (Gmail, Outlook...): lọc thư rác (spam classification), hộp thư ưu tiên (priority inbox), trích xuất sự kiện (calendar event extraction), tự động hoàn thành (auto-complete).
- Voice-based assistants (Apple Siri, Google Assistant, Microsoft Cortana, Amazon Alexa...): tương tác với người dùng, hiểu các lệnh của người dùng và phản hồi phù hợp
- Modern search engines (Google, Bing...): hiểu, mở rộng truy vấn, (query understanding, query expansion), trả lời câu hỏi (question answering), truy xuất thông tin (information retrieval), xếp hạng và nhóm kết quả tìm kiếm (ranking and grouping of the results).
- Machine translation services (Google Translate, Bing Microsoft Translator, Amazon Translate...): các dịch vụ dịch máy.

■ Các ứng dụng khác (other applications)...


Các nhiệm vụ NLP (NLP tasks)

- Mô hình ngôn ngữ (**Language modeling**)
 - Dự đoán từ tiếp theo trong câu dựa trên lịch sử của các từ trước đó
 - Nhận dạng giọng nói (speech recognition), ký tự (optical character recognition), chữ viết tay (handwriting recognition), dịch máy (machine translation), sửa lỗi chính tả (spelling correction).
- Phân loại văn bản (**Text classification**)
 - Lọc thư rác (email spam identification), phân tích cảm xúc (sentiment analysis)
- Trích xuất thông tin (**Information extraction**)
- Truy xuất thông tin (**Information retrieval**)
 - Google search...
- Tác tử hội thoại (**Conversational agent**)
 - Alexa, Siri...

Các nhiệm vụ NLP (NLP tasks)

- Tóm tắt văn bản (Text summarization)
- Hỏi đáp (Question answering)
- Dịch máy (Machine translation)
- Mô hình hóa/phân tích chủ đề (Topic modelling)
 - Công cụ khai thác văn bản (text-mining) phổ biến và được sử dụng rộng rãi trong nhiều lĩnh vực, từ văn học (literature) đến tin sinh học (bioinformatics).

Độ khó tương đối (relative difficulty)



Ngôn ngữ là gì?

■ Ngôn ngữ (Language)

- Hệ thống giao tiếp có cấu trúc bao gồm sự kết hợp phức tạp của các thành phần cấu tạo của nó, như ký tự (**characters**), từ (**words**), câu (**sentences**)...

■ Ngôn ngữ học (Linguistics)


- ngành nghiên cứu ngôn ngữ một cách có hệ thống (**systematic study of language**).

■ Để nghiên cứu NLP, điều quan trọng là phải hiểu một số khái niệm từ ngôn ngữ học về cấu trúc của ngôn ngữ.

■ Ngôn ngữ của con người được cấu thành từ bốn khối (**building blocks**) chính:

- Âm vị (**phonemes**), Hình vị (**morphemes**), Từ vị (**lexemes**), Cú pháp (**syntax**), và Ngữ cảnh (**context**).

Các khối chính



Âm vị (phonemes)

- Đơn vị âm thanh (**units of sound**) nhỏ nhất của một ngôn ngữ

Consonant phonemes, with sample words		Vowel phonemes, with sample words	
1. /b/ - bat	13. /s/ - sun	1. /a/ - ant	13. /oi/ - coin
2. /k/ - cat	14. /t/ - tap	2. /e/ - egg	14. /ar/ - farm
3. /d/ - dog	15. /v/ - van	3. /i/ - in	15. /or/ - for
4. /f/ - fan	16. /w/ - wig	4. /o/ - on	16. /ur/ - hurt
5. /g/ - go	17. /y/ - yes	5. /u/ - up	17. /air/ - fair
6. /h/ - hen	18. /z/ - zip	6. /ai/ - rain	18. /ear/ - dear
7. /j/ - jet	19. /sh/ - shop	7. /ee/ - feet	19. /ure/ ⁴ - sure
8. /l/ - leg	20. /ch/ - chip	8. /igh/ - night	20. /ə/ - corner (the 'schwa' - an unstressed vowel sound which is close to /u/)
9. /m/ - map	21. /th/ - thin	9. /oa/ - boat	
10. /n/ - net	22. /th/ - then	10. /oo/ - boot	
11. /p/ - pen	23. /ng/ - ring	11. /oo/ - look	
12. /r/ - rat	24. /zh/ ³ - vision	12. /ow/ - cow	

Hình vị (morphemes)

- Đơn vị ngôn ngữ nhỏ nhất có nghĩa
 - Tạo thành bằng cách kết hợp (combination) các âm vị (phonemes)

unbreakable
un + break + able


cats
cat + s

tumbling
tumble + ing

unreliability
un + rely + able + ity

Từ vị (lexemes)

- Biến thể cấu trúc (**structural variations**) của hình vị có mối liên hệ với nhau về nghĩa.




Cú pháp (syntax)

- Tập hợp các quy tắc (**rules**) để xây dựng các câu đúng ngữ pháp (**grammatically**) từ các từ (**words**) và cụm từ (**phrases**) trong một ngôn ngữ.
 - Phương pháp phổ biến để biểu diễn câu là cây phân tích cú pháp.
- Cú pháp của một ngôn ngữ có thể rất khác so với ngôn ngữ khác
 - các phương pháp xử lý ngôn ngữ cũng sẽ thay đổi tương ứng

2 câu có cú pháp tương tự
(*syntactically similar sentences*)

- N: noun
- V: verb
- P: preposition
- NP: noun phrase
- VP: verb phrase
- PP: preposition phrase
- Det: Determiner



Cấu trúc phân cấp
(*hierarchical*)

- Từ (word): cấp thấp nhất
- Thẻ từ loại (part-of-speech tag)
- Cụm từ (phrase)
- Câu (sentence): cấp cao nhất

Ngữ cảnh (context)

- Cách các thành phần khác nhau trong ngôn ngữ kết hợp với nhau để truyền đạt một ý nghĩa cụ thể.
 - Ngữ cảnh bao gồm:
 - các tham chiếu lâu dài (long-term references)
 - kiến thức về thế giới (world knowledge)
 - lẽ thường (common sense) cùng với nghĩa đen (literal meaning) của từ và cụm từ
- ý nghĩa của một câu có thể thay đổi dựa trên ngữ cảnh
- Nói chung, ngữ cảnh được cấu thành từ:
 - ngữ nghĩa (semantics): ý nghĩa trực tiếp của từ (direct meaning)
 - không có ngữ cảnh bên ngoài
 - ngữ dụng (pragmatics): ngụ ý (implied meaning)
 - Bổ sung thêm kiến thức về thế giới và ngữ cảnh bên ngoài của cuộc hội thoại

Tại sao NLP lại khó khăn? (Why Is NLP Challenging?)

■ Tính nhập nhằng, mơ hồ (ambiguity)

- Không chắc chắn (**uncertainty**) của ý nghĩa

The man couldn't lift his son because he was so **weak**. ———○ Who was weak?

The man couldn't lift his son because he was so **heavy**. ———○ Who was heavy?

Mary and Sue are **sisters**.
Mary and Sue are **mothers**. } ———○ How are Mary and Sue related?

Joan made sure to thank Susan for all the help she had **received**. ———○ Who had received help?

Joan made sure to thank Susan for all the help she had **given**. ———○ Who had given help?

John **promised** Bill to leave, so an hour later he left.
John **ordered** Bill to leave, so an hour later he left. } ———○ Who left an hour later?

Tại sao NLP lại khó khăn? (Why Is NLP Challenging?)

- Kiến thức phổ thông (common knowledge)
 - Tập hợp tất cả các sự kiện mà con người đều hiểu biết, nhận thức
 - “man bit dog”
 - “dog bit man”
- Tính sáng tạo (creativity)
- Tính đa dạng (diversity across languages)

Machine Learning, Deep Learning và NLP

■ Trí tuệ nhân tạo (artificial intelligence – AI): Thập niên 1950

- Nhánh của khoa học máy tính (**computer science**) nhằm xây dựng các hệ thống có thể thực hiện các công việc đòi hỏi trí thông minh con người (**human intelligence**)
- Hay còn gọi “machine intelligence”
- AI ban đầu chủ yếu xây dựng dựa trên logic, phương pháp phỏng đoán (**heuristics**), và các hệ thống dựa trên quy tắc/luật (**rule-based systems**)


■ Học máy (machine learning – ML)

- Nhánh của AI, phát triển các thuật toán có khả năng thực hiện công việc tự động dựa trên số lượng lớn các ví dụ (tập dữ liệu huấn luyện) mà không cần các quy tắc thủ công
- Supervised learning, Unsupervised learning, Re-inforcement learning

■ Học sâu (deep learning – DL)

- Nhánh của học máy dựa trên kiến trúc mạng nơ-ron nhân tạo (**artificial neural network**)

Machine Learning, Deep Learning và NLP



Các phương pháp tiếp cận (Approaches to NLP)

- Các phương pháp khác nhau được sử dụng để giải quyết các bài toán xử lý ngôn ngữ tự nhiên thường được chia thành ba loại:

- Phương pháp phỏng đoán (Heuristics-Based NLP)

- Phân tích cảm xúc dựa trên từ vựng (Lexicon-based sentiment analysis)
- Mạng Wordnet
- Biểu thức chính quy (Regular expressions - regex)
- ...

- Học máy (Machine Learning for NLP)

- Naive Bayes
- Support vector machine (SVM)
- Hidden Markov Model (HMM)
- Conditional random fields


- Học sâu (Deep Learning for NLP)

- Recurrent neural networks (RNNs)
- Long short-term memory (LSTM)
- Convolutional neural networks (CNNs)
- Transformers
- Autoencoders

Wordnet


■ Các mối quan hệ ngữ nghĩa (semantic relationships):

- Đồng nghĩa (Synonyms)
- Is-type-of (Hyponyms)
 - Football, tennis cùng loại “sport”
- Is-part-of (Meronyms)
 - Hands, legs là phần của “body”




Đồ thị Wordnet cho từ “sport”


Support vector machine (SVM)




Hidden Markov Model (HMM)




Recurrent neural networks (RNN)



Long short-term memory (LSTM)

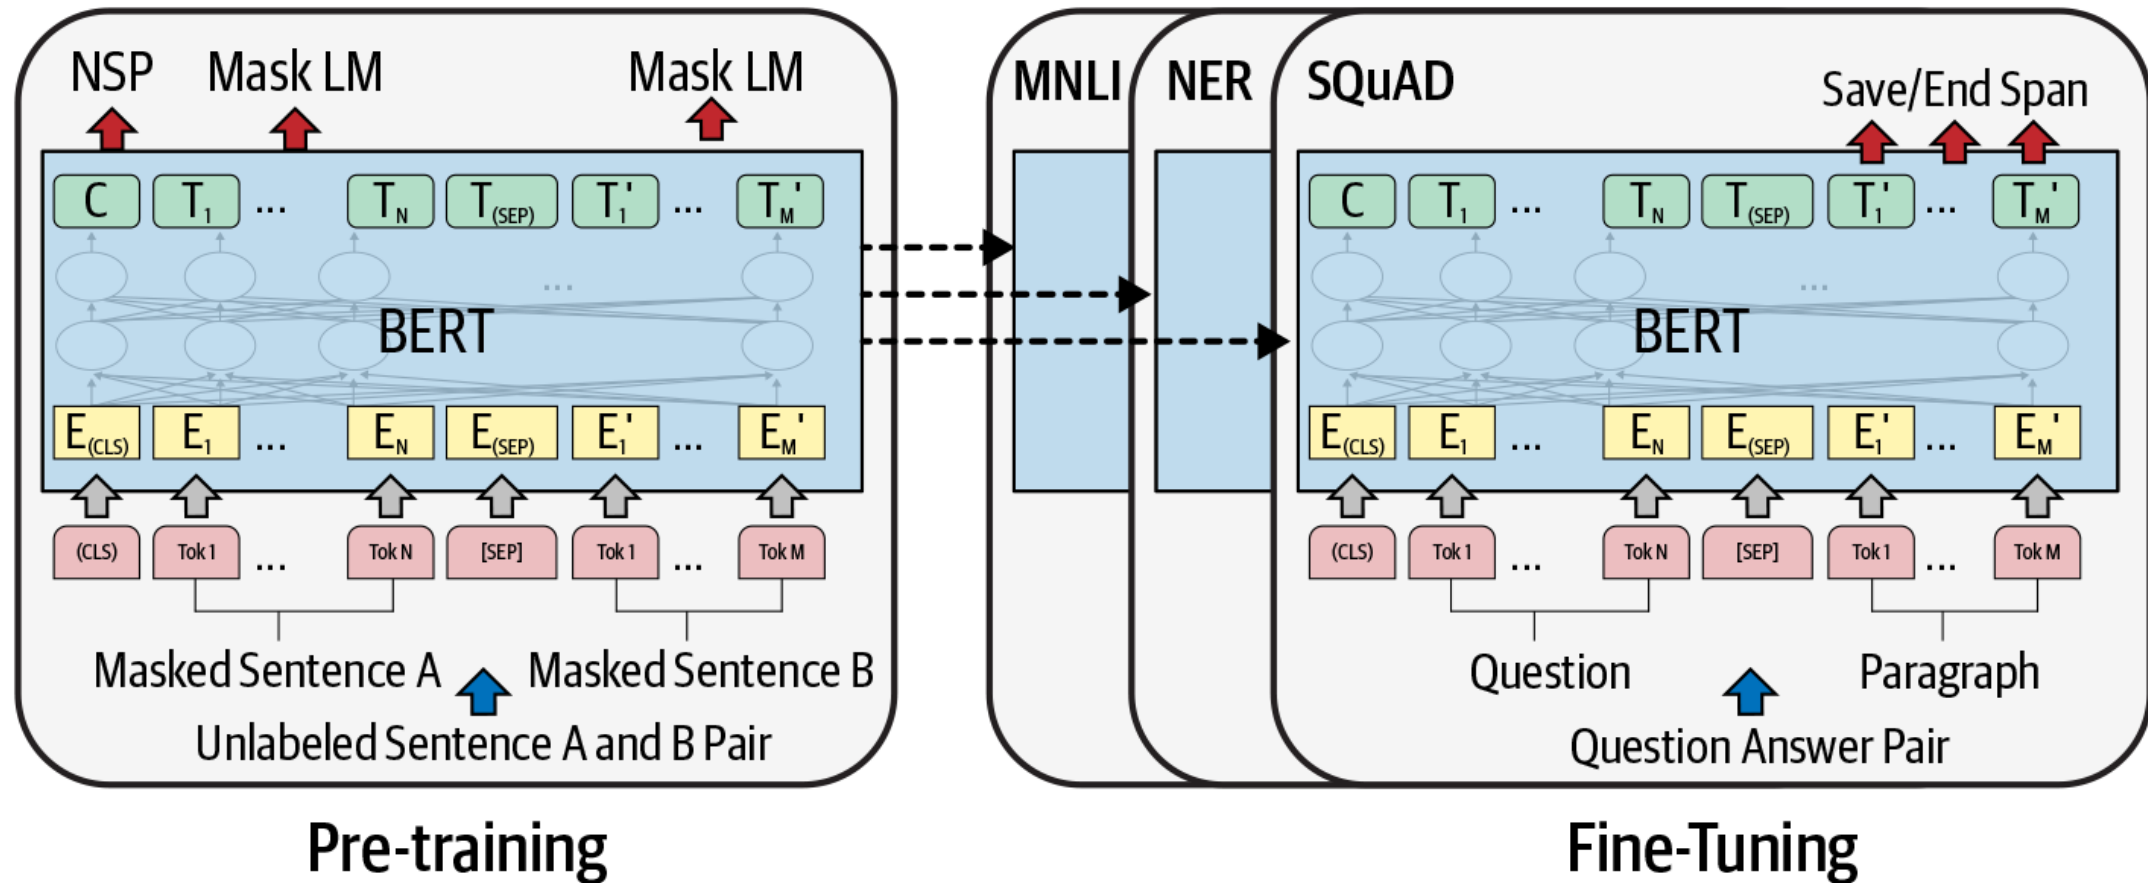


Convolutional neural networks (CNN)




Transformers

- Một ví dụ của “large transformer” là BERT (Bidirectional Encoder Representations from Transformers)




Transformers

- Cơ chế “Self-attention” trong một transformer




Autoencoders



NLP pipeline

- Quá trình xử lý văn bản từng bước này được gọi là **pipeline**
 - Đó là chuỗi các bước liên quan đến việc xây dựng bất kỳ mô hình NLP nào.
- Các giai đoạn chính trong quy trình như sau:
 1. Thu thập dữ liệu (Data acquisition)
 2. Làm sạch văn bản (Text cleaning)
 3. Tiền xử lý (Pre-processing)
 4. Kỹ thuật đặc trưng (Feature engineering)
 5. Mô hình hóa (Modeling)
 6. Đánh giá (Evaluation)
 7. Triển khai (Deployment)
 8. Giám sát và cập nhật mô hình (Monitoring and model updating)

NLP pipeline



- Sinh viên đọc thêm tài liệu (xem như phần bài tập thực hành)
 - [1] Chapter 1, 2. Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta, and Harshit Surana, *Practical Natural Language Processing*. O'Reilly, 2020.

