

Gán Nhãn Từ Loại (Part-of-Speech Tagging)

Xử Lý Ngôn Ngữ Tự Nhiên
(Natural Language Processing - NLP)
Vũ Đình Khôi

Nội dung

- Khái niệm
- Tập từ loại tiếng Anh
- Tập nhãn cho tiếng Anh
- Tập từ loại tiếng Việt
- Tập nhãn cho tiếng Việt
- Các phương pháp gán nhãn từ loại
 - Sequence Labeling for Part of Speech

- [1] Chapter 17. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
 - <https://web.stanford.edu/~jurafsky/slp3/>
 - File: 17_Part-of-Speech_POSNER_intro_May_6_2021.pptx
- [2] Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta, and Harshit Surana, *Practical Natural Language Processing*. O'Reilly, 2020.
- [3] Jay Alammam and Maarten Grootendorst, *Hands-On Large Language Models*. O'Reilly, 2024.
- [4] Suhas Pai, *Designing Large Language Model Applications*. O'Reilly, 2025.

Chỉ cần đọc các Chapter được liệt kê

I find that I don't understand things unless I try to program them.



Donald E. Knuth

Professor Emeritus at Stanford University

If you want to **master something**, teach it



-- **Richard Feynman**

- Truyền thống ngôn ngữ học (**linguistic**) thời sơ khai nhất (*Yaska and Panini 5th C. BCE, Aristotle 4th C. BCE*) đã có ý tưởng các từ (**words**) có thể phân loại (**classify**) thành các nhóm phạm trù ngữ pháp (**grammatical categories**) được gọi là:
 - từ loại (**part of speech**), lớp từ (**word classes**), POS, thẻ POS (**POS tags**)
- 8 từ loại được cho là của Dionysius Thrax thành Alexandria (c. 1st C. BCE):
 - Danh từ (**noun**), động từ (**verb**), đại từ (**pronoun**), giới từ (**preposition**), trạng từ (**adverb**), liên từ (**conjunction**), phân từ (**participle**), mạo từ (**article**)
- Đến nay, những phạm trù này vẫn còn phù hợp với Xử lý ngôn ngữ tự nhiên (NLP).

Hai loại từ: từ mở (open) và từ đóng (closed)

■ Từ loại đóng (closed class words)

- Thành viên tương đối cố định (Relatively fixed membership)
- Thường là các từ chức năng (function): những từ ngắn, thường dùng có chức năng ngữ pháp
 - Định từ (determiners): a, an, the
 - Đại từ (pronouns): she, he, I
 - Giới từ (prepositions): on, under, over, near, by, ...

■ Từ loại mở (open class words)

- Thường là các từ nội dung (content): danh từ (nouns), động từ (verbs), tính từ (adjectives), trạng từ (adverbs)
 - Thêm thán từ (interjections): oh, ouch, uh-huh, yes, hello
- Các danh từ và động từ mới như:
 - iPhone hoặc to fax

Open class ("content") words

Nouns

Proper

Janet
Italy

Common

cat, cats
mango

Verbs

Main

eat
went

Adjectives

old green tasty

Adverbs

slowly yesterday

Numbers

122,312
one

Interjections *ow hello*

... more

Closed class ("function")

Determiners *the some*

Conjunctions *and or*

Pronouns *they its*

Auxiliary

can
had

Prepositions *to with*

Particles *off up*


... more

Gắn thẻ từ loại (Part-of-Speech Tagging)

- Xác định hoặc gán (**assigning**) một từ loại (**part-of-speech/POS**) cho mỗi từ trong văn bản.
- Một số từ thường có nhiều hơn một từ loại (**POS**).
- Ví dụ, từ **book**
 - VERB: (**Book** that flight)
 - NOUN: (Hand me that **book**)

Gắn thẻ từ loại (Part-of-Speech Tagging)

- Ánh xạ (**map**) chuỗi các từ (**sequence of words**) $x_1, \dots, x_n$ sang chuỗi các từ loại (**POS tags**) $y_1, \dots, y_n$



"Universal Dependencies" Tagset

	Tag	Description	Example
Open Class	ADJ	Adjective: noun modifiers describing properties	<i>red, young, awesome</i>
	ADV	Adverb: verb modifiers of time, place, manner	<i>very, slowly, home, yesterday</i>
	NOUN	words for persons, places, things, etc.	<i>algorithm, cat, mango, beauty</i>
	VERB	words for actions and processes	<i>draw, provide, go</i>
	PROPN	Proper noun: name of a person, organization, place, etc..	<i>Regina, IBM, Colorado</i>
	INTJ	Interjection: exclamation, greeting, yes/no response, etc.	<i>oh, um, yes, hello</i>
Closed Class Words	ADP	Adposition (Preposition/Postposition): marks a noun's spacial, temporal, or other relation	<i>in, on, by under</i>
	AUX	Auxiliary: helping verb marking tense, aspect, mood, etc.,	<i>can, may, should, are</i>
	CCONJ	Coordinating Conjunction: joins two phrases/clauses	<i>and, or, but</i>
	DET	Determiner: marks noun phrase properties	<i>a, an, the, this</i>
	NUM	Numeral	<i>one, two, first, second</i>
	PART	Particle: a preposition-like form used together with a verb	<i>up, down, on, off, in, out, at, by</i>
	PRON	Pronoun: a shorthand for referring to an entity or event	<i>she, who, I, others</i>
Other	SCONJ	Subordinating Conjunction: joins a main clause with a subordinate clause such as a sentential complement	<i>that, which</i>
	PUNCT	Punctuation	<i>; , ()</i>
	SYM	Symbols like \$ or emoji	<i>\$, %</i>
	X	Other	<i>asdf, qwfg</i>

Penn Treebank core 36 part-of-speech tags

Tag	Description	Example	Tag	Description	Example	Tag	Description	Example
CC	coord. conj.	<i>and, but, or</i>	NNP	proper noun, sing.	<i>IBM</i>	TO	infinitive to	<i>to</i>
CD	cardinal number	<i>one, two</i>	NNPS	proper noun, plu.	<i>Carolinas</i>	UH	interjection	<i>ah, oops</i>
DT	determiner	<i>a, the</i>	NNS	noun, plural	<i>llamas</i>	VB	verb base	<i>eat</i>
EX	existential 'there'	<i>there</i>	PDT	predeterminer	<i>all, both</i>	VBD	verb past tense	<i>ate</i>
FW	foreign word	<i>mea culpa</i>	POS	possessive ending	<i>'s</i>	VBG	verb gerund	<i>eating</i>
IN	preposition/ subordin-conj	<i>of, in, by</i>	PRP	personal pronoun	<i>I, you, he</i>	VBN	verb past partici- ple	<i>eaten</i>
JJ	adjective	<i>yellow</i>	PRP\$	possess. pronoun	<i>your</i>	VBP	verb non-3sg-pr	<i>eat</i>
JJR	comparative adj	<i>bigger</i>	RB	adverb	<i>quickly</i>	VBZ	verb 3sg pres	<i>eats</i>
JJS	superlative adj	<i>wildest</i>	RBR	comparative adv	<i>faster</i>	WDT	wh-determ.	<i>which, that</i>
LS	list item marker	<i>1, 2, One</i>	RBS	superlatv. adv	<i>fastest</i>	WP	wh-pronoun	<i>what, who</i>
MD	modal	<i>can, should</i>	RP	particle	<i>up, off</i>	WP\$	wh-possess.	<i>whose</i>
NN	sing or mass noun	<i>llama</i>	SYM	symbol	<i>+, %, &</i>	WRB	wh-adverb	<i>how, where</i>

Figure 17.2 Penn Treebank core 36 part-of-speech tags.

Sample "Tagged" English sentences

- There/**PRO** were/**VERB** 70/**NUM** children/**NOUN** there/**ADV** ./**PUNC**
- Preliminary/**ADJ** findings/**NOUN** were/**AUX** reported/**VERB** in/**ADP**
today/**NOUN** 's/**PART** New/**PROPN** England/**PROPN** Journal/**PROPN** of/**ADP**
Medicine/**PROPN**

Tại sao phải gán thẻ từ loại?

- Có thể hữu ích cho các tác vụ (tasks) Xử lý ngôn ngữ tự nhiên (NLP) khác
 - Phân tích cú pháp (**Parsing**): Gán thẻ từ loại (**POS tagging**) có thể cải thiện phân tích cú pháp (**syntactic parsing**)
 - Dịch máy (**Machine translation**): sắp xếp lại các tính từ và danh từ (**reordering of adjectives and nouns**), ví dụ tiếng Việt tính từ đứng sau danh từ
 - Phân tích cảm xúc hoặc tình cảm (**Sentiment or affective tasks**): có thể muốn phân biệt tính từ và các từ loại khác (**distinguish adjectives or other POS**)
 - Chuyển văn bản thành giọng nói (**Text-to-speech**): phát âm từ “lead”, “record” hay “object” như thế nào phụ thuộc vào từ loại?
- Hoặc các tác vụ tính toán ngôn ngữ học hoặc phân tích ngôn ngữ (**linguistic or language-analytic computational tasks**)
 - Cần kiểm soát từ loại khi nghiên cứu sự thay đổi ngôn ngữ như tạo ra từ mới hoặc sự thay đổi nghĩa (**creation of new words, or meaning shift**)
 - Hoặc kiểm soát từ loại khi đo lường sự tương đồng hoặc khác biệt về nghĩa (**measuring meaning similarity or difference**)

Khó khăn trong gán thẻ từ loại trong tiếng Anh

- Khoảng 15% loại từ có nghĩa mơ hồ (**ambiguous**)
 - Do đó, 85% loại từ còn lại không có nghĩa mơ hồ (**unambiguous**)
 - “Janet” luôn là danh từ/PROP, “hesitantly” luôn là trạng từ/ADV
- Nhưng 15% đó lại rất phổ biến (**very common**)
- Vì vậy, khoảng ~60% token (**word tokens**) có nghĩa mơ hồ (**ambiguous**)
- Ví dụ, từ “back”
 - earnings growth took a **back/ADJ** seat
 - a small building in the **back/NOUN**
 - a clear majority of senators **back/VERB** the bill
 - enable the country to buy **back/PART** debt
 - I was twenty-one **back/ADV** then

Hiệu suất gán thẻ POS trong tiếng Anh

- Có bao nhiêu thẻ chính xác (**Tag accuracy**)?
 - Khoảng 97%
 - Không thay đổi trong hơn 10 năm qua (**last 10+ years**)
 - Các mô hình HMMs, CRFs, BERT có hiệu suất tương tự (**perform similarly**)
 - Độ chính xác do người thực hiện (**human accuracy**) cũng tương tự
- Nhưng mức cơ sở (**baseline**) là 92%!
 - Mức cơ sở là hiệu suất của phương pháp đơn giản nhất có thể (**stupidest possible method**)
 - “Mức cơ sở lớp phổ biến (**“Most frequent class baseline”**): là mức quan trọng cho nhiều tác vụ
 - Gán thẻ cho mỗi từ với thẻ phổ biến nhất (**most frequent tag**) của nó
 - Và gán thẻ cho các từ chưa biết là danh từ (**tag unknown words as nouns**)
 - Một phần dễ dàng vì
 - Nhiều từ không gây nhầm lẫn (**unambiguous**)

Nguồn thông tin cho việc gán thẻ POS

Janet will back the bill

AUX/NOUN/VERB?

NOUN/VERB?

- Xác suất tiên nghiệm của từ/thẻ (Prior probabilities of word/tag)
 - "will" thường là trợ động từ (AUX)
- Nhận dạng các từ liền kề (Identity of neighboring words)
 - "the" có nghĩa là từ tiếp theo có thể không phải một động từ (not a verb)
- Hình thái học (Morphology) và cấu trúc từ (wordshape):
 - Tiền tố (Prefixes) unable: un- → tính từ (ADJ)
 - Hậu tố (Suffixes) importantly: -ly → tính từ (ADJ)
 - Viết hoa (Capitalization) Janet: CAP → danh từ (PROPN)

Các thuật toán chuẩn để gán thẻ POS

- Các thuật toán Học có giám sát (Supervised Machine Learning Algorithms):
 - Mô hình Markov ẩn (Hidden Markov Models)
 - Conditional Random Fields (CRF)/ Maximum Entropy Markov Models (MEMM)
 - Mô hình chuỗi thần kinh (Neural sequence models (RNNs hoặc Transformers))
 - Mô hình ngôn ngữ lớn (Large Language Models (như BERT), được tinh chỉnh (finetuned))
- Tất cả [thuật toán] đều yêu cầu một tập dữ liệu huấn luyện được gán nhãn thủ công (hand-labeled training set), hiệu suất (performance) gần như nhau (97% trên tiếng Anh)
- Tất cả đều sử dụng các nguồn thông tin mà chúng ta đã thảo luận
 - Thông qua các đặc trưng do con người tạo ra (human created features): HMM và CRF
 - Thông qua học biểu diễn (representation learning): Mô hình ngôn ngữ thần kinh

Hidden Markov Model (HMM) Part-of-Speech Tagging


HMM Part-of-Speech Tagging

■ Tham khảo

- [1] Chapter 17. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
 - File: [17_Sequence Labeling for Parts of Speech and Named Entities.pdf](#)

$Q = q_1 q_2 \dots q_N$	a set of N states
$A = a_{11} \dots a_{ij} \dots a_{NN}$	a transition probability matrix A , each a_{ij} representing the probability of moving from state i to state j , s.t. $\sum_{j=1}^N a_{ij} = 1 \quad \forall i$
$B = b_i(o_t)$	a sequence of observation likelihoods , also called emission probabilities , each expressing the probability of an observation o_t (drawn from a vocabulary $V = v_1, v_2, \dots, v_V$) being generated from a state q_i
$\pi = \pi_1, \pi_2, \dots, \pi_N$	an initial probability distribution over states. π_i is the probability that the Markov chain will start in state i . Some states j may have $\pi_j = 0$, meaning that they cannot be initial states. Also, $\sum_{i=1}^n \pi_i = 1$

HMM Part-of-Speech Tagging



HMM Part-of-Speech Tagging

