

Nhận Dạng Thực Thể (Named Entity Recognition)

Xử Lý Ngôn Ngữ Tự Nhiên
(Natural Language Processing - NLP)

Vũ Đình Khôi

Nội dung

- Khái niệm
- Một số phương pháp nhận dạng thực thể có tên/định danh
- Ứng dụng

- [1] Chapter 17. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
 - <https://web.stanford.edu/~jurafsky/slp3/>
 - File: *17_Part-of-Speech_POSNER_intro_May_6_2021.pptx*
- [2] Chapter 5. Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta, and Harshit Surana, *Practical Natural Language Processing*. O'Reilly, 2020.
- [3] Chapter 11. Jay Alammara and Maarten Grootendorst, *Hands-On Large Language Models*. O'Reilly, 2024.
- [4] Suhas Pai, *Designing Large Language Model Applications*. O'Reilly, 2025.

Chỉ cần đọc các Chapter được liệt kê

**I find that I don't understand things unless I try
to program them.**



Donald E. Knuth

Professor Emeritus at Stanford University

If you want to **master something**, teach it



-- Richard Feynman

Named Entities

- Thực thể định danh (**Named entity**) trong NLP là bất cứ thứ gì (các đối tượng cụ thể trong văn bản) có thể được gọi/đặt tên/định danh bằng một tên riêng (**proper name**). Bốn thẻ phổ biến nhất (**most common tags**) là:
 - PER (**Person**): “Marie Curie” Nhân vật
 - LOC (**Location**): “New York City” Địa điểm
 - ORG (**Organization**): “Stanford University” Tổ chức
 - GPE (**Geo-Political Entity**): “Boulder, Colorado” Thực thể địa-chính trị
- Thường là các cụm từ nhiều từ (**multi-word phrases**)
- Nhưng thuật ngữ (**term**) này cũng được mở rộng cho những thứ không phải là thực thể (**entities**) như:
 - Ngày tháng (**dates**), thời gian (**times**), giá cả (**prices**)

Named Entity Recognition (NER)

- Nhiệm vụ phụ rất quan trọng: **tìm** và **phân loại** tên trong văn bản
(A very important sub-task: **find** and **classify** names in text)
- Danh sách các loại thực thể chung (**generic named entity types**)

Type	Tag	Sample Categories	Example sentences
People	PER	people, characters	Turing is a giant of computer science.
Organization	ORG	companies, sports teams	The IPCC warned about the cyclone.
Location	LOC	regions, mountains, seas	Mt. Sanitas is in Sunshine Canyon .
Geo-Political Entity	GPE	countries, states	Palo Alto is raising the fees for parking.

Gắn thẻ thực thể định danh (Named Entity tagging)

- Nhiệm vụ của nhận dạng thực thể định danh (Named Entity Recognition – NER):
 - Tìm các văn bản tạo thành tên riêng (find spans of text that constitute proper names)
 - Gắn thẻ loại thực thể (tag the type of the entity)
- Kết quả (output) của NER

Citing high fuel prices, [ORG United Airlines] said [TIME Friday] it has increased fares by [MONEY \$6] per round trip on flights to some cities also served by lower-cost carriers. [ORG American Airlines], a unit of [ORG AMR Corp.], immediately matched the move, spokesman [PER Tim Wagner] said. [ORG United], a unit of [ORG UAL Corp.], said the increase took effect [TIME Thursday] and applies to most routes where it competes against discount carriers, such as [LOC Chicago] to [LOC Dallas] and [LOC Denver] to [LOC San Francisco].

Tại sao Nhận dạng thực thể định danh (NER)?

- Phân tích cảm xúc (**Sentiment analysis**):
 - Cảm xúc của người tiêu dùng đối với một công ty hay cá nhân cụ thể?
- Hỏi đáp (**Question Answering**):
 - Trả lời các câu hỏi về một thực thể?
- Trích xuất thông tin (**Information Extraction**):
 - Trích xuất/rút ra các thông tin (**extracting facts**) về các thực thể từ văn bản

Vì sao nhận dạng thực thể định danh (NER) lại khó?

■ Phân đoạn/tách từ (Segmentation)

- Trong gán thẻ (POS tagging), không có vấn đề phân đoạn vì mỗi từ được gán một thẻ (each word gets one tag).
- Trong NER chúng ta phải tìm (find) và phân đoạn (segment) các thực thể!

■ Sự mơ hồ về kiểu dữ liệu (Type ambiguity)

- Ví dụ, sự mơ hồ về kiểu chữ trong việc sử dụng tên Washington

[PER Washington] was born into slavery on the farm of James Burroughs.

[ORG Washington] went up 2 games to 1 in the four-game series.

Blair arrived in [LOC Washington] for what may well be his last state visit.

In June, [GPE Washington] passed a primary seatbelt law.

BIO (Begin-Inside-Outside) Tagging

- Làm sao chúng ta có thể biến bài toán có cấu trúc (**structured problem**) này thành bài toán trình tự (**sequence problem**) như gắn thẻ POS, với một nhãn cho mỗi từ (**POS tagging, with one label per word**)?
 - BIO (**B**egin-**I**nside-**O**utside) tagging: là phương pháp gắn nhãn chuỗi (**sequence labeling**) trong NLP, đặc biệt cho các bài toán như Nhận dạng thực thể định danh (**NER**)
 - Ví dụ: “Nguyen Van Thanh studied at Hoa Sen”
 - Nguyễn: B-PER; Văn: I-PER; Thành: I-PER
 - studied: O; at: O
 - Hoa: B-ORG; Sen: I-ORG
- [**PER** Jane Villanueva] of [**ORG** United] , a unit of [**ORG** United Airlines Holding] , said the fare applies to the [**LOC** Chicago] route.

BIO Tagging

- [_{PER} Jane Villanueva] of [_{ORG} United] , a unit of [_{ORG} United Airlines Holding] , said the fare applies to the [_{LOC} Chicago] route.

Words	BIO Label
Jane	B-PER
Villanueva	I-PER
of	O
United	B-ORG
Airlines	I-ORG
Holding	I-ORG
discussed	O
the	O
Chicago	B-LOC
route	O
.	O

Bây giờ chúng ta có một thẻ cho mỗi token (**one tag per token**)!!!

BIO Tagging

- B: token bắt đầu (*begins*) một span
- I: tokens trong (*inside*) một span
- O: tokens ngoài (*outside*) bất kỳ span nào
- Số lượng thẻ (n là số loại thực thể (# entity types):
 - 1 thẻ O (O tag)
 - do kết thúc của tất cả các loại (phụ thuộc vào các thẻ trước nó)
 - n thẻ B (B tags)
 - n thẻ I (I tags)
- Tổng cộng $(2n + 1)$ thẻ

Words	BIO Label
Jane	B-PER
Villanueva	I-PER
of	O
United	B-ORG
Airlines	I-ORG
Holding	I-ORG
discussed	O
the	O
Chicago	B-LOC
route	O
.	O

Các biến thể BIO Tagging (variants): IO and BIOES

- [_{PER} Jane Villanueva] of [_{ORG} United] , a unit of [_{ORG} United Airlines Holding] , said the fare applies to the [_{LOC} Chicago] route.

Words	IO Label	BIO Label	BIOES Label
Jane	I-PER	B-PER	B-PER
Villanueva	I-PER	I-PER	E-PER
of	O	O	O
United	I-ORG	B-ORG	B-ORG
Airlines	I-ORG	I-ORG	I-ORG
Holding	I-ORG	I-ORG	E-ORG
discussed	O	O	O
the	O	O	O
Chicago	I-LOC	B-LOC	S-LOC
route	O	O	O
.	O	O	O

- Học máy có giám sát (**Supervised Machine Learning**) được cung cấp tập dữ liệu huấn luyện gồm văn bản có chú thích với thẻ do con người gán nhãn (**human-labeled training set of text annotated with tags**)
 - Mô hình Markov ẩn (**Hidden Markov Models**)
 - **Conditional Random Fields (CRF)/ Maximum Entropy Markov Models (MEMM)**
 - Mô hình chuỗi thần kinh (**Neural sequence models (RNNs hoặc Transformers)**)
 - Mô hình ngôn ngữ lớn (**Large Language Models (như BERT), được tinh chỉnh (fine-tuned)**)

HMM Part-of-Speech Tagging

- Hidden Markov Model (**HMM**): mô hình Markov ẩn
 - Mô hình kinh điển (**classic model**)
- Mô hình chuỗi xác suất (**probabilistic sequence model**)
 - cho trước một chuỗi các đơn vị (từ/**words**, chữ cái/**letters**, hình vị/**morphemes**, câu/**sentences**, bất cứ thứ gì), nó tính toán phân bố xác suất (**probability distribution**) trên các chuỗi nhãn có thể có và chọn chuỗi nhãn tốt nhất.

