

Công nghệ Tiếng nói

Course ID: AI409DV01

Lecturer: Bùi Ngọc Lê

Email: le.buingoc@hoasen.edu.vn

Chapter 07

Nhận dạng giọng nói (Speech recognition)

Nội dung


- Mô hình kênh nhiễu,
- Kiến trúc ASR & chỉ số tỷ lệ lỗi từ (WER)
- ASR với Mô hình Markov Ẩn
- Lịch sử phát triển

Giới thiệu

- Mục tiêu: Với âm thanh được cung cấp, hãy tạo bản ghi chính xác các từ của người nói.
- Phiên âm **nguyên gốc**: Ghi lại mọi âm "ừm", cụm từ rời rạc, sự lặp lại và sự không trôi chảy để bảo toàn tín hiệu giọng nói thực sự.
- Bản ghi làm **Sạch**: được lược bỏ hoặc chuẩn hóa các lỗi giọng nói nhỏ và từ thừa, mang lại kết quả trôi chảy hơn, dễ đọc hơn.
- Hoạt động **thời gian thực, độ trễ thấp**: Đối với các cài đặt tương tác (trợ lý giọng nói, phụ đề trực tiếp), ASR phải xử lý âm thanh khi nhận được. Giữ độ trễ đầu cuối dưới 200 ms để có luồng hội thoại tự nhiên.
- Hạn chế trên Thiết bị biên: Cần chạy ASR trên các thiết bị không hỗ trợ đám mây. Tính toán + bộ nhớ có thể bị hạn chế

Mô hình kênh nhiễu

- Tìm kiếm trong không gian dữ liệu tất cả các câu có thể.
- Chọn câu có khả năng xảy ra cao nhất dựa trên dạng sóng



Mô hình kênh nhiễu

- Trong tất cả các câu trong ngôn ngữ L , câu nào có khả năng tạo ra một số tín hiệu âm thanh O nhất định?
- Coi tín hiệu âm thanh O như một chuỗi các quan sát riêng lẻ
 - $O = o_1, o_2, o_3, \dots, o_t$
- Định nghĩa một câu như một chuỗi các từ:
 - $W = w_1, w_2, w_3, \dots, w_n$

Mô hình kênh nhiễu


- Hàm xác suất: Chọn chuỗi từ có xác suất cao nhất W :

$$\hat{W} = \operatorname{argmax}_{W \in L} P(W | O)$$

- Sử dụng định lý Bayes để viết lại như sau:
$$\hat{W} = \operatorname{argmax}_{W \in L} \frac{P(O | W)P(W)}{P(O)}$$
- Chúng ta có thể bỏ qua nó đối với argmax:
$$\hat{W} = \operatorname{argmax}_{W \in L} P(O | W)P(W)$$
- Bỏ qua mẫu số, chúng ta còn lại hai yếu tố: $P(\text{Nguồn})$ và $P(\text{Tín hiệu}|\text{Nguồn})$

Mô hình kênh nhiễu

- Giọng nói kết hợp với kênh nhiễu



Tỷ lệ lỗi từ (WER)

- Tỷ lệ lỗi từ

$$\text{Word Error Rate} = 100 \times \frac{\text{Insertions} + \text{Substitutions} + \text{Deletions}}{\text{Total Words in Correct Transcript}}$$


Can be >100%.

Doesn't distinguish between function words (of, they, he, she) and more important content words

- Ví dụ:

REF:	i	***	**	UM	the	PHONE	IS		i	LEFT	THE	portable	****	PHONE	UPSTAIRS	last	night
HYP:	i	GOT	IT	TO	the	*****	FULLEST	i	LOVE	TO	portable	FORM	OF		STORES	last	night
Eval:	I	I	S		D	S		S	S			I	S	S			


Kiến trúc ASR



ASR với Mô hình Markov Ẩn (HMM-GMM)


- Trích xuất đặc trưng:
 - 39 đặc trưng MFCC
- Mô hình âm học:
 - Mô hình hỗn hợp Gauss (GMM) để ước tính $p(o|q)$
- Mô hình từ điển/Phát âm
 - HMM: những gì âm từ có thể theo sau nhau. Ràng buộc chuỗi từ từ điển ngữ âm
- Mô hình ngôn ngữ
 - N-gram để tính toán $p(w_i|w_{i-1})$
- Bộ giải mã
 - Thuật toán Viterbi: lập trình động để kết hợp tất cả các phần để ước tính chuỗi từ từ âm thanh

ASR với Mô hình Markov Ẩn (HMM-GMM)



Mô hình Markov Ẩn (HMM)

- Mô hình Markov ẩn (HMM) là một loại mô hình AI thống kê được sử dụng để phân tích dữ liệu tuần tự
- Ý tưởng cốt lõi là đưa ra các suy luận về một chuỗi các trạng thái ẩn dựa trên một chuỗi các đầu ra có thể quan sát được.
- Ví dụ:
 - x — Các trạng thái trong mô hình
 - a — Các xác suất chuyển tiếp
 - b — Các xác suất đầu ra
 - y — Các dữ liệu quan sát



Mô hình Markov Ẩn (HMM)

- Ví dụ:


- trạng thái = ('Mưa', 'Nắng')
- dữ liệu quan sát = ('đi dạo', 'đi chợ', 'dọn phòng')
- khả_năng_ban_đầu = {'Mưa': 0.6, 'Nắng': 0.4}
- khả_năng_chuyển_dịch = {
 'Mưa' : {'Mưa': 0.7, 'Nắng': 0.3},
 'Nắng' : {'Mưa': 0.4, 'Nắng': 0.6},
}
- khả_năng_loại_bỏ = {
 'Mưa' : {'đi dạo': 0.1, 'đi chợ': 0.4, 'dọn phòng': 0.5},
 'Nắng' : {'đi dạo': 0.6, 'đi chợ': 0.3, 'dọn phòng': 0.1},
}

Mô hình Markov Ẩn (HMM)

- Ví dụ:
 - khả_năng_ban_đầu: cho thấy không chắc về trạng thái HMM
 - khả_năng_chuyển_dịch: cho thấy những thay đổi về thời tiết trong chuỗi Markov.
 - Khả_năng_loại_bỏ: cho thấy anh bạn thích làm những việc gì mỗi ngày
- ➔
- Giả sử bạn quan sát chuỗi hành vi sau trong 3 ngày:
[đi dạo, đi chợ, dọn phòng]
- Dùng HMM để suy đoán chuỗi thời tiết tương ứng:
Có thể là: [Nắng, Nắng, Mưa]

Mô hình Markov Ẩn (HMM)


- HMM dự đoán ký tự:
 - Mô hình chuỗi HMM
 - Dựa vào từ điển phát âm được mã hóa cứng
 - Các trạng thái HMM được lựa chọn cẩn thận cho phép các mô hình ít mạnh hơn xử lý mô hình âm thanh $p(\text{audio} | \text{state})$



Rút trích đặc tính âm thanh(MFCCs)



- Mel-scale

- Thính giác của con người không nhạy cảm như nhau với mọi dải tần số
- Ít nhạy cảm hơn ở tần số cao hơn, > 1000 Hz
- Tức là cảm nhận của con người về tần số không tuyến tính:



Rút trích đặc tính âm thanh(MFCCs)

- Ngân hàng Lọc Mel
 - Khoảng cách gần như đồng đều trước 1 kHz
 - thang logarit sau 1 kHz




Rút trích đặc tính âm thanh(MFCCs)

- Các tính năng MFCC điển hình cho HMM-GMM
 - Window size: 25ms
 - Window shift: 10ms
 - Pre-emphasis coefficient (hệ số nhấn mạnh): 0.97
 - MFCC:
 - 12 MFCC (mel frequency cepstral coefficients)
 - 1 energy feature
 - 12 delta MFCC features
 - 12 double-delta MFCC features
 - 1 delta energy feature
 - 1 double-delta energy feature
 - Tổng 39 trường thuộc tính
 - MFCC phù hợp với các hệ thống HMM-GMM và tài nguyên tính toán hạn chế.
 - Các mô hình hiện đại không phụ thuộc nhiều vào MFCC, chúng là một trong nhiều phép biến đổi đặc trưng đầu vào khả thi.

Rút trích đặc tính âm thanh(MFCCs)

- Sơ đồ tính toán MFCC



Lịch sử phát triển

- Thập niên 1950–1970: Khởi đầu sơ khai
 - 1952: Bell Labs phát triển hệ thống "Audrey" – nhận diện chữ số nói từ một người dùng.
 - 1960s: IBM và các viện nghiên cứu phát triển hệ thống nhận diện từ đơn lẻ, chủ yếu dùng kỹ thuật phân tích phổ âm thanh.
 - Giới hạn: Chỉ nhận diện được vài từ, không có khả năng xử lý ngôn ngữ liên tục.
- Thập niên 1980–1990: Mô hình thống kê và HMM
 - Hidden Markov Models (HMM) trở thành nền tảng cho ASR hiện đại, cho phép nhận diện chuỗi từ thay vì từ đơn lẻ.
 - Dynamic Time Warping (DTW) được dùng để so khớp mẫu âm thanh.
 - 1990s: Các công ty như Dragon Systems ra mắt phần mềm nhận dạng giọng nói thương mại cho PC.

Lịch sử phát triển

- Thập niên 2000: ASR thương mại hóa
 - ASR được tích hợp vào điện thoại, hệ thống IVR (tổng đài tự động), và phần mềm văn phòng.
 - Google Voice Search (2008) và Siri (2011) đánh dấu bước ngoặt khi ASR trở thành tính năng phổ biến trên smartphone.
- Thập niên 2010–nay: Học sâu và mô hình end-to-end
 - Deep Learning thay thế HMM truyền thống bằng mạng nơ-ron sâu (DNN, CNN, RNN, LSTM).
 - Mô hình end-to-end như DeepSpeech, Wav2Vec, và Whisper giúp đơn giản hóa pipeline xử lý và tăng độ chính xác.
 - ASR hiện đại có thể xử lý giọng nói đa ngôn ngữ, nhận diện trong môi trường nhiễu, và hiểu ngữ cảnh.

Q & A

