

Báo Cáo Đồ Án Môn Học

Máy Học – Machine Learning

Lớp: 1008 Học Kỳ: 2531

Đề Tài

Phân Loại Naïve Bayesian & Kỹ Thuật Ước Lượng Laplace (Laplace Estimator)

Giảng Viên Hướng Dẫn

Người Thực Hiện

ThS. Phan Hồng Trung

22302421 – Nguyễn Phúc Minh Châu

22303711 – Hà Đăng Ngọc

Thành phố Hồ Chí Minh, ngày 27 tháng 12 năm 2025

Lời Cảm Ơn

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất tới Thầy Th.S Phan Hồng Trung – người đã trực tiếp giảng dạy và tận tình hướng dẫn em trong suốt quá trình học tập môn Machine Learning cũng như trong thời gian thực hiện bài báo cáo này.

Chúng em xin cảm ơn Thầy vì đã không chỉ truyền dạy kiến thức chuyên môn mà còn luôn sẵn lòng dành thời gian giải đáp những thắc mắc, đưa ra những định hướng quý báu và những góp ý để bài báo cáo của nhóm em được hoàn thiện một cách chu đáo nhất. Sự nhiệt huyết và phong cách làm việc chuyên nghiệp của Thầy chính là nguồn động lực lớn lao, giúp chúng em hiểu rằng học máy không chỉ là những dòng code hay công thức toán học, mà còn là tư duy giải quyết vấn đề để tạo ra những giá trị thực tiễn cho cuộc sống.

Bản báo cáo này là kết quả của sự nỗ lực học tập của chúng em dưới sự dìu dắt của Thầy. Dù đã cố gắng hoàn thành với tất cả sự tập trung, nhưng do kiến thức và kinh nghiệm thực tế còn hạn chế, bài làm của em chắc chắn vẫn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự phê bình và những chỉ dẫn thêm từ Thầy để có thể tiến bộ hơn sau này.

Cuối cùng, chúng em xin kính chúc Thầy luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công rực rỡ hơn nữa trong sự nghiệp giảng dạy và nghiên cứu khoa học.

Chúng em xin chân thành cảm ơn Thầy!

Mục Lục

Lời Cảm Ơn.....	1
Mục Lục	1
Danh Mục Hình Ảnh.....	2
Nội Dung Báo Cáo	3
I. Tổng Quan Về Lý Thuyết	3
1. Định Lý Bayes – Bayes’ Theorem	3
2. Phân Loại Naïve Bayesian - Naïve Bayesian Classified.....	3
3. Laplace Estimator (Laplace Smoothing).....	4
II. Đồ Án Môn Học	4
1. Giới Thiệu Naïve Bayes Trong Thư Viện Scikit Learn.....	4
2. Quá Trình Thực Hiện Đồ Án.....	5
3. Demo Application	10
Tài Liệu Tham Khảo	11

Danh Mục Hình Ảnh

Hình 1: Dữ liệu huấn luyện mô hình.....	6
Hình 2: Code chạy phân loại Naive Bayes không Laplace	6
Hình 3: Code chạy phân loại Naive Bayes có Laplace	6
Hình 4: Kết quả phân loại Naive Bayes không Laplace.....	7
Hình 5: Kết quả phân loại Naive Bayes có Laplace	7
Hình 6: Confussion Matrix – Không có Laplace (bên trái); Có Laplace (bên phải)	7
Hình 7: Accuracy – Không có Laplace (bên trái); Có Laplace (bên phải).....	8
Hình 8: Classification Metrics – Không có Laplace (màu xanh); Có Laplace (màu cam)	8
Hình 9: Predicted Probabilities – Không có Laplace (bên trái); Có Laplace (bên phải)	9
Hình 10: Zero Probability- Không có Laplace (màu xanh); Có Laplace (màu cam)	9
Hình 11: Demo Application – Eng	10
Hình 12: Demo Application – Vie.....	10

Nội Dung Báo Cáo

I. Tổng Quan Về Lý Thuyết

1. Định Lý Bayes – Bayes' Theorem

Định lý được đặt tên theo **Thomas Bayes** - mục sư, nhà thống kê và triết gia, định lý Bayes được ông viết vào cuốn sách “**An Essay Towards Solving a Problem in the Doctrine of Chances**” được xuất bản năm **1763**, mang theo công trình nghiên cứu của Bayes về cách tính phân phối cho tham số xác suất của phân phối nhị thức.

Theo **Định lý Bayes (Bayes Theorem)**, cho phép tính *xác suất hậu nghiệm có khả năng xảy ra (posterior probability)* một sự kiện ngẫu nhiên A khi biết sự kiện liên quan B đã xảy ra $[P(A|B)]$. Điều này xảy ra được dựa trên 3 yếu tố:

- Xác suất xảy ra sự kiện ngẫu nhiên A độc lập $[P(A)]$ - Xác suất tiên nghiệm (*prior*)
- Xác suất sự kiện B xảy ra một cách độc lập $[P(B)]$ - Đại lượng hằng số chuẩn hóa (*normalising constant / evidence*), vì nó luôn giống nhau (mặc định)
- Đại lượng khả năng (*likelihood*) – Xác suất sự kiện B xảy ra khi có sự kiện A xảy ra/điển ra

Khi đã biết được cả 3 yếu tố này, chúng ta sẽ rút kết được công thức của Định lý Bayes:

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)} \quad \text{Posterior} = \frac{\text{Likelihood} * \text{Prior}}{\text{Evidence}}$$

2. Phân Loại Naïve Bayesian - Naïve Bayesian Classified

Phân loại Naive Bayesian (**Naive Bayesian Classified**) là một cách thức phân loại đơn giản áp dụng vào hệ số tính xác suất của **Định lý Bayes (Bayes' Theorem)** với **giả định** các điểm đặc trưng đầu vào tách biệt/độc lập với nhau (trên thực tế các đặc trưng ít nhiều có liên quan tới nhau).

Trong cơ chế phân loại, giả sử chúng ta có một dải vector dữ liệu là đối tượng cần được phân loại $\mathbf{X} = (x_1, x_2, \dots, x_n)$ với n điểm đặc trưng độc lập, và chúng ta có c_j biểu thị một trong các lớp $\mathbf{K}$. Chúng ta sẽ dùng thuật toán của Naive Bayes sao cho **xác suất hậu nghiệm (posterior probability)** $[P(c_j|\mathbf{X})]$ cho từng lớp c_j ($j = 1$ tới K).

Với quyết định phân loại cho đối tượng cần được phân loại X sẽ được gán cho lớp c_k khi và chỉ khi:

$$P(c_k|X) > P(c_j|X) \text{ for } 1 \leq j \leq K, j \neq k$$

Lấy một ví dụ đơn giản về phòng bệnh, ta có X là bệnh nhân với các triệu chứng $(x_1, x_2, \dots, x_n)$ với K là danh sách các bệnh c_j có khả năng mang những chịu chứng n . Dù vậy bác sĩ Naive Bayes cho rằng tất cả các bệnh nhân đang có không liên quan tới nhau nên phân tích từng riêng từng triệu chứng rồi kết hợp lại những trường hợp khả thi để dò ra bệnh khả thi nằm trong danh sách bệnh.

3. Laplace Estimator (Laplace Smoothing)

Đặt ra một vấn đề là trong việc sử dụng Naive Bayes vào học máy có những **xác suất hậu nghiệm bằng 0 (zero probability)**. Điều này có thể làm sai lệch kết quả tập huấn luyện. Để giải quyết vấn đề này thì chúng ta sẽ cần dùng phương pháp Laplace Estimator.

Laplace Estimator (Laplace Smoothing) hay còn gọi là Additive Smoothing, Lidstone Smoothing. Đây là một phương pháp hiệu chuẩn xác suất bằng cách cộng thêm 1 vào mỗi số đếm và cộng số lượng giá trị có thể có của thuộc tính vào mẫu số.

$$P(x_i|c) = \frac{n_{x_i,c} + 1}{n_c + k}$$

$n_{x_i,c}$: Số lần giá trị x_i xuất hiện trong lớp c
 n_c : Tổng số mẫu trong lớp c
 k : Số lượng giá trị khả thi của thuộc tính x_i

II. Đồ Án Môn Học

1. Giới Thiệu Naïve Bayes Trong Thư Viện Scikit Learn

Scikit Learn là một thư viện thân thuộc khi giúp chúng ta có thể học tập, quan sát nhanh cách các thuật toán hoạt động. Thư viện có thể được ứng dụng nhanh vào các dự án nhỏ khi hầu hết các thuật toán cơ bản đã được đưa vào tích hợp bên trong thư viện.

Trong đó Naïve Bayes được đưa vào Scikit Learn với rất nhiều biến thể trong tệp `sklearn.naive_bayes` để tối ưu cho các loại phân phối dữ liệu khác nhau:

1. **GaussianNB**: Dùng cho dữ liệu số thực liên tục tuân theo phân phối chuẩn (ví dụ: chiều cao, cân nặng, nhiệt độ) Multinomial Naive Bayes

2. **MultinomialNB**: Dùng cho dữ liệu dạng đếm tần suất, là chuẩn mực cho phân loại văn bản và lọc thư rác.
3. **ComplementNB**: Phiên bản cải tiến của MultinomialNB, chuyên dùng để xử lý dữ liệu bị mất cân bằng nghiêm trọng giữa các lớp.
4. **BernoulliNB**: Dùng cho dữ liệu nhị phân (0/1) chỉ quan tâm sự kiện có xuất hiện hay không (ví dụ: văn bản ngắn)
5. **CategoricalNB**: Dùng cho dữ liệu dạng danh mục/nhãn rời rạc không có thứ tự (ví dụ: màu sắc, giới tính, loại xe).
6. **Out-of-core model fitting**: Kỹ thuật huấn luyện mô hình từng phần (batch) dành cho tập dữ liệu quá lớn không thể chứa hết trong RAM.

Trong Scikit-Learn, kỹ thuật Laplace Estimator được điều khiển thông qua tham số alpha. Khi bạn khởi tạo mô hình Naive Bayes, công thức toán học thực tế mà Scikit-Learn tính toán cho xác suất của đặc trưng i trong lớp y là:

$$P(x_i|y) = \frac{N_{yi} + \alpha}{N_y + \alpha * n}$$

N_{yi}: Số lần đặc trưng i xuất hiện trong lớp y

N_y: Tổng số tất cả các đặc trưng trong lớp y

n: Số lượng đặc trưng

α : Hệ số smoothing (Additive smoothing parameter)

Cơ chế hoạt động của tham số alpha:

- **Trường hợp alpha = 1.0 (Mặc định)**: Đây hệ số Laplace Smoothing. Scikit-Learn đặt giá trị mặc định là 1.0 để đảm bảo ngay lập tức giải quyết vấn đề xác suất bằng 0 mà người dùng không cần cấu hình gì thêm.
- **Trường hợp 0 < alpha < 1**: Đây được gọi là Lidstone Smoothing. Đôi khi trong nghiên cứu, việc cộng 1 là quá mạnh (quá aggressive), làm giảm độ nhạy của dữ liệu thực. Các nhà nghiên cứu có thể giảm α xuống (ví dụ 0.1 hoặc 0.5) để giữ lại nhiều đặc tính gốc của dữ liệu hơn.
- **Trường hợp alpha = 0**: Mô hình quay về với cách tính thông thường của Naive Bayes. Mô hình sẽ dễ gặp lỗi **"Zero Probability"** như chúng ta đã phân tích.

2. Quá Trình Thực Hiện Đồ Án

Trong quá trình thực hiện đồ án, nhóm xác định mục tiêu là nghiên cứu sâu hơn về phân loại Naive Bayesian và Laplace Smoothing. Nên nhóm quyết định chọn thực hiện một bài demo đơn giản trong việc phân loại trạng thái cảm xúc qua từ ngữ. Nhằm tập trung vào sâu hơn về việc tìm hiểu điểm khác nhau giữa một mô hình Naive Bayesian khi có và không sử dụng Laplace Estimator (Laplace Smoothing).

Về dữ liệu đầu vào dùng để huấn luyện mô hình máy học, nhóm đã sử dụng hai dataset sentiment từ hai bảng tiếng Anh và tiếng Việt với lượng dữ liệu lớn nhằm có thể dễ quan sát được khi trong lúc huấn luyện mô hình có **xác suất bằng 0 (zero probability)**. Về tập dữ liệu đã được chuẩn hóa thủ công từ trước và chỉ có hai cột giá trị là text (các câu từ ngữ thường ngày) và sentiment (trạng thái cảm xúc, chỉ có 3 trạng thái là positive, neutral và negative).

0.3s Open 'df' in Data Wrangler

text	sentiment
Missing: 0 (0%)	Missing: 0 (0%)
Distinct: 57736 (92%)	Distinct: 3 (<1%)
57736 Distinct values	positive: 49% neutral: 26% negative: 25%

0	Cooking microwave pizzas, yummy	positive
1	Any plans of allowing sub tasks to st	neutral
2	I love the humor, I just reworded it. I	positive
3	naw idk what ur talkin about	neutral
4	That sucks to hear. I hate days like th	negative
5	Umm yeah. That's probably a pretty	positive
6	whatever do you mean?	neutral
7	That would panic me a little! Maybe	negative
8	Is sad when people's phones are dei	negative
9	sad face.	negative

62,668 rows x 2 cols 10 per page

Hình 1: Dữ liệu huấn luyện mô hình

Khi bắt tay thực hiện vào mô hình, nhóm thống nhất sử dụng module **ComplementNB** sau khi cân nhắc sử dụng **ComplementNB** và **MultinomialNB**. Vì nhận thấy mô hình **ComplementNB** có tính chọn lọc khắt khe hơn trong việc xử lý các dữ liệu dễ mất cân bằng của hai bộ dataset. **ComplementNB** cho ra độ chính xác cao hơn trong huấn luyện cũng như dễ nhận biết sự khác biệt hơn khi phân biệt giữa hai mô hình khi có và không sử dụng Laplace.

1. Model without Laplace Estimator (Laplace Smoothing)

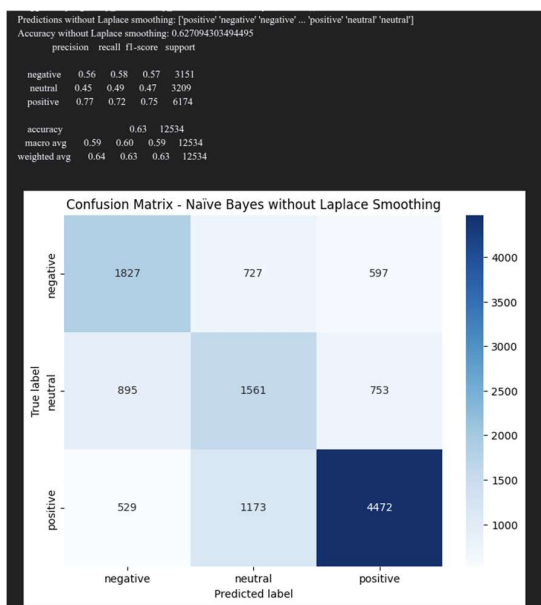
```
1 #model training without Laplace smoothing
2 modelNBC = nb.ComplementNB(alpha=0.0)
3 modelNBC.fit(X_train_vec, y_train)
4
5 #make predictions
6 y_pred_1 = modelNBC.predict(X_test_vec)
7 print('Predictions without Laplace smoothing:', y_pred_1)
8 #evaluate model
9 print('Accuracy without Laplace smoothing:', accuracy_score(y_test, y_pred_1))
10 print(classification_report(y_test, y_pred_1))
11
12 #Plot confusion matrix
13 cm = confusion_matrix(y_test, y_pred_1)
14 plt.figure(figsize=(8,6))
15 sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
16 #ticklabels=modelNBC.classes_, yticklabels=modelNBC.classes_)
17 plt.title('Confusion Matrix - Naive Bayes without Laplace Smoothing')
18 plt.ylabel('True label')
19 plt.xlabel('Predicted label')
20 plt.show()
```

Hình 2: Code chạy phân loại Naive Bayes không Laplace


2. Model with Laplace Estimator (Laplace Correction)

```
1 #model training with Laplace smoothing (alpha=1)
2 modelNBC_Laplace = nb.ComplementNB(alpha=1.0)
3 modelNBC_Laplace.fit(X_train_vec, y_train)
4 #make predictions
5 y_pred_2 = modelNBC_Laplace.predict(X_test_vec)
6 print('Predictions with Laplace smoothing:', y_pred_2)
7 #evaluate model
8 print('Accuracy with Laplace smoothing:', accuracy_score(y_test, y_pred_2))
9 print(classification_report(y_test, y_pred_2))
10
11 #Plot confusion matrix
12 cm = confusion_matrix(y_test, y_pred_2)
13 plt.figure(figsize=(8,6))
14 sns.heatmap(cm, annot=True, fmt='d', cmap='Purples')
15 #ticklabels=modelNBC_Laplace.classes_, yticklabels=modelNBC_Laplace.classes_)
16 plt.title('Confusion Matrix - Naive Bayes with Laplace Smoothing')
17 plt.ylabel('True label')
18 plt.xlabel('Predicted label')
19 plt.show()
```

Hình 3: Code chạy phân loại Naive Bayes có Laplace




Hình 4: Kết quả phân loại Naive Bayes **không** Laplace



Hình 5: Kết quả phân loại Naive Bayes **có** Laplace

Dựa vào từ hai kết quả thực nghiệm bên trên giữa khi sử dụng mô hình học máy Naive Bayes mà không và có sử dụng Laplace Smoothing. Phân tích từ tổng quan có thể dễ dàng nhìn thấy:

Confusion Matrix:




Hình 6: Confussion Matrix – Không có Laplace (bên trái); Có Laplace (bên phải)

Có thể nhìn thấy sự cải thiện rõ rệt khi sử dụng Laplace Smoothing, nhất nằm ở lớp **Neutral**. Khi không có Laplace, mô hình gặp khó khăn do hiện tượng xác suất bằng 0, chỉ dự đoán đúng 1561 mẫu. Với Laplace, con số này tăng vọt lên **1826 mẫu** (+265 mẫu), chứng tỏ khả năng tổng quát hóa tốt hơn trên các văn bản không chứa từ khóa cảm xúc mạnh.

Đặc biệt, kỹ thuật này giúp giảm thiểu sai lầm nghiêm trọng nhất trong kinh doanh: dự đoán nhầm **Positive thành Negative**. Số lượng lỗi này giảm mạnh từ 529 xuống còn **327 trường hợp** (gần 40%). Tổng thể, ma trận chuyển dịch từ xu hướng

thiên lệch gán nhầm nhiều nhãn Negative sang trạng thái cân bằng, tách bạch rõ ràng hơn ranh giới giữa Neutral và các lớp còn lại.

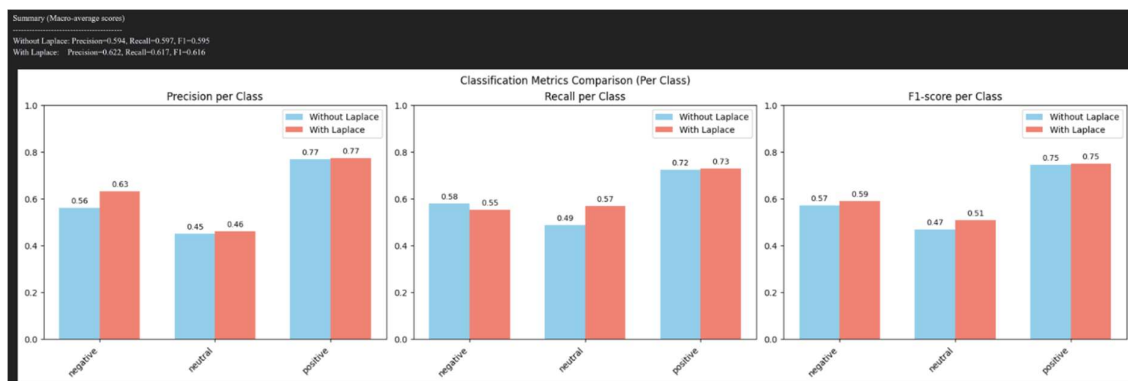
Accuracy:



Hình 7: Accuracy – Không có Laplace (bên trái); Có Laplace (bên phải)

Việc áp dụng Laplace Smoothing đã giúp **tăng độ chính xác tổng thể lên khoảng 1.7%**. Với tập dữ liệu kiểm thử là 12,534 mẫu, con số 1.7% tương đương với việc mô hình dự đoán đúng thêm được khoảng **200 mẫu dữ liệu**.

Classification Metrics (Recall, F1, Precision):



Hình 8: Classification Metrics – Không có Laplace (màu xanh); Có Laplace (màu cam)


Biểu đồ trực quan hóa rõ nét sự ưu việt của mô hình có sử dụng Laplace Smoothing (cột màu đỏ) so với mô hình gốc (cột màu xanh).

Điểm nổi bật nhất nằm ở sự đánh đổi hiệu quả giữa hai chỉ số:

- **Về Precision (Độ chuẩn xác):** Lớp Negative có tăng từ 0.56 lên 0.63, cho thấy mô hình đã lọc nhiễu tốt hơn và các dự đoán tiêu cực trở nên đáng tin cậy hơn.
- **Về Recall (Độ nhạy):** Lớp Neutral tăng mạnh từ 0.49 lên 0.57, khắc phục điểm yếu bỏ sót dữ liệu trung tính của mô hình cũ.

Ở biểu đồ **F1-score**, đường màu đỏ luôn cao hơn hoặc bằng đường màu xanh ở mọi lớp, đặc biệt kéo lớp yếu nhất là Neutral từ 0.47 lên 0.51, khẳng định tính ổn định toàn diện của giải pháp này.

Predicted Probabilities:




Hình 9: Predicted Probabilities – Không có Laplace (bên trái); Có Laplace (bên phải)

Biểu đồ so sánh cho thấy tác động kỹ thuật của Laplace Smoothing lên giá trị đầu ra của mô hình. Ở biểu đồ bên trái (không dùng Laplace), dữ liệu tập trung dày đặc tại các điểm cực trị (gần 0 và 1), tạo nên các khoảng gián đoạn trong phân phối.

Ngược lại, biểu đồ bên phải (có dùng Laplace) cho thấy đường cong mật độ xác suất trở nên liên tục và phân tán đều hơn về phía trung tâm. Điều này chứng tỏ kỹ thuật làm trơn đã thực hiện chức năng **hiệu chỉnh xác suất (Probability Calibration)**, ngăn chặn việc gán giá trị xác suất tuyệt đối cho các mẫu dữ liệu thưa. Kết quả là mô hình giảm thiểu hiện tượng quá khớp (overfitting) và tăng khả năng tổng quát hóa khi xử lý dữ liệu kiểm thử.

Zero Probability Problem:



Hình 10: Zero Probability- Không có Laplace (màu xanh); Có Laplace (màu cam)

Biểu đồ cột thể hiện sự tương phản cực đại về tính ổn định số học giữa hai mô hình. Đối với mô hình không sử dụng Laplace, số lượng mẫu bị gán xác suất bằng 0 xuất hiện dày đặc ở cả ba lớp, cao nhất là lớp **Neutral với 1432 trường hợp**.

Mô hình sử dụng Laplace ghi nhận giá trị **bằng 0 tuyệt đối** ở tất cả các lớp. Sự so sánh này xác nhận kỹ thuật Laplace Smoothing đã loại bỏ hoàn toàn hiện tượng triệt tiêu xác suất, đảm bảo mọi mẫu dữ liệu đều có giá trị xác suất dương ($P > 0$) để phục vụ quá trình tính toán hậu nghiệm.

3. Demo Application

Từ những gì đã chuẩn bị bên trên, nhóm viết ra một interface đơn giản và dễ sử dụng để demo mô hình học máy phân loại Naive Bayesian. Cho phép người dùng nhập vào bất kỳ văn bản nào bằng tiếng Anh hay tiếng Việt. Sau đó chỉ cần bấm nút “Predict Sentiment” màu xanh lá cây hệ thống sẽ đưa text người dùng yêu cầu, gọi các hàm bên trên để chạy mô hình.

Sau cùng mô hình sẽ hiển thị kết quả dự đoán cùng chỉ số accuracy từ cả hai mô hình phân loại Naive Bayesian khi có và không sử dụng Laplace Estimator.

PREDICTION RESULT

Input Text: "Hello World"

Without Laplace Smoothing: neutral (confidence: 0.4143)

With Laplace Smoothing: neutral (confidence: 0.3980)

✓ Both models agree

Hình 11: Demo Application – Eng

PREDICTION RESULT

Input Text: "Xin chào Thế Giới"

Without Laplace Smoothing: negative (confidence: 0.4730)

With Laplace Smoothing: negative (confidence: 0.4454)

✓ Both models agree

Hình 12: Demo Application – Vie

Tài Liệu Tham Khảo

Additive smoothing. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Additive_smoothing

Bayes estimator. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Bayes_estimator

Bayes' theorem. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Bayes%27_theorem

Định lý Bayes. (n.d.). Trong *Wikipedia*. Retrieved December 29, 2025, from https://vi.wikipedia.org/wiki/%C4%90%E1%BB%8Bnh_l%C3%BD_Bayes

GeeksforGeeks. (n.d.). *Additive smoothing techniques in language models*. Retrieved December 29, 2025, from <https://www.geeksforgeeks.org/additive-smoothing-techniques-in-language-models/>

GeeksforGeeks. (n.d.). *Naive Bayes classifiers*. Retrieved December 29, 2025, from <https://www.geeksforgeeks.org/naive-bayes-classifiers/>

George James Lidstone. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/George_James_Lidstone

Laplace transform. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Laplace_transform

Laplacian smoothing. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Laplacian_smoothing

Naive Bayes classifier. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Naive_Bayes_classifier

Order of succession. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Order_of_succession

Pierre-Simon Laplace. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Pierre-Simon_Laplace

Posterior probability. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Posterior_probability

Rule of succession. (n.d.). In *Wikipedia*. Retrieved December 29, 2025, from https://en.wikipedia.org/wiki/Rule_of_succession

Scikit-learn developers. (n.d.). *1.9. Naive Bayes*. Scikit-learn 1.8.0 documentation. Retrieved December 29, 2025, from https://scikit-learn.org/stable/modules/naive_bayes.html

Xác suất có điều kiện. (n.d.). Trong *Wikipedia*. Retrieved December 29, 2025, from https://vi.wikipedia.org/wiki/X%C3%A1c_su%E1%BA%A5t_c%C3%B3_%C4%91i%E1%BB%81u_ki%E1%BB%87n

Mohammed, M., Khan, M. B., & Bashier, E. B. M. (2017). *Machine learning algorithms and applications*. CRC Press.