


DEEP LEARNING

NỀN TẢNG LÝ THUYẾT CÁC MÔ HÌNH HỌC SÂU

www.hoasen.edu.vn


Chương 6



The universal workflow
of Machine Learning
Quy trình tổng quát của Học Máy

The universal workflow of Machine Learning


Quy trình tổng quát của Học Máy



- Giới thiệu
- Xác định nhiệm vụ
- Phát triển mô hình
- Triển khai mô hình

DEEP LEARNING

NỀN TẢNG LÝ THUYẾT CÁC MÔ HÌNH HỌC SÂU



Introduction Giới thiệu

The universal workflow of Machine Learning

Quy trình tổng quát của Học Máy

- Machine Learning trong thực tế không bắt đầu từ dataset.
- Thực tế thường bắt đầu từ một bài toán cần giải quyết.
- Quy trình tổng quát gồm 3 phần:
 - Define the task – Xác định nhiệm vụ.
 - Develop a model – Phát triển mô hình.
 - Deploy the model – Triển khai mô hình.
- Mục tiêu: hiểu toàn bộ vòng đời của một dự án ML.

Why a Universal Workflow? Vì sao cần quy trình tổng quát?

- Giúp tiếp cận có hệ thống với nhiều loại bài toán ML.
- Tránh bắt đầu bằng việc chọn model quá sớm.
- Giúp kết nối mục tiêu kinh doanh với giải pháp kỹ thuật.
- Giúp kiểm soát dữ liệu, đánh giá, triển khai và bảo trì.
- Áp dụng cho classification, regression, ranking, recommendation...

Three Main Phases – Ba giai đoạn chính

- Ba giai đoạn này tạo thành vòng đời ML đầy đủ.
- Sau deployment, mô hình vẫn cần được theo dõi.
- Ví dụ: hệ thống fraud detection phải cập nhật vì hành vi gian lận thay đổi.

1. Define the task – Xác định nhiệm vụ

Hiểu bài toán, dữ liệu, mục tiêu.

Quyết định bài toán có khả thi không.

2. Develop a model – Phát triển mô hình

Chuẩn bị dữ liệu, train, đánh giá, tuning.

Tập trung vào mô hình và khả năng generalization.

3. Deploy the model – Triển khai mô hình

Đưa vào môi trường thật, giám sát, bảo trì.

Kiểm tra mô hình trong môi trường thực tế.


Ethics in Machine Learning

Đạo đức trong Học Máy

- Công nghệ không trung lập.
- Một số bài toán có thể gây rủi ro đạo đức.
- Dataset có thể chứa thiên kiến của con người.
- Model có thể khuếch đại thiên kiến ở quy mô lớn.
- Cần cân nhắc giá trị xã hội của hệ thống ML.

DEEP LEARNING

NỀN TẢNG LÝ THUYẾT CÁC MÔ HÌNH HỌC SÂU



Define the Task
Xác định nhiệm vụ

Define the Task – Xác định nhiệm vụ

- Cần hiểu sâu bối cảnh trước khi làm model.
- Xác định:
 - Vấn đề cần giải quyết là gì?
 - Ai sẽ sử dụng kết quả?
 - Giá trị tạo ra là gì?
 - Dữ liệu nào đang có hoặc có thể thu thập?
- Mục tiêu: biến bài toán thực tế thành bài toán ML rõ ràng.

Frame the Problem – Định hình bài toán

- Xác định input data.
- Xác định target cần dự đoán.
- Kiểm tra ML có phải giải pháp phù hợp không.
- Xác định loại bài toán ML:
 - Binary classification.
 - Multiclass classification.
 - Regression.
 - Ranking.
 - Recommendation.
 - Image segmentation.

Examples of ML Task Framing

Ví dụ định hình bài toán ML

Bài toán thực tế

Bài toán ML

Photo search engine
(Công cụ tìm kiếm ảnh)

Multiclass classification

Spam detection
(Phát hiện thư rác)

Binary classification hoặc multiclass
classification

Credit card fraud
(Phát hiện gian lận thẻ tín dụng)

Binary classification

Click-through rate prediction
(Dự đoán tỷ lệ nhấp chuột)

Scalar regression

Archeological site search
(Tìm kiếm địa điểm khảo cổ)

Image-similarity ranking

Understand Existing Solutions

Hiểu giải pháp hiện có

- Trước khi xây model, cần hỏi:
 - Hiện tại bài toán được xử lý thế nào?
 - Có rule-based system không?
 - Có con người đang xử lý thủ công không?
 - Điểm yếu của giải pháp hiện tại là gì?
- ML nên cải thiện hoặc hỗ trợ quy trình hiện có.

Constraints – Các ràng buộc của bài toán

- Các ràng buộc cần xem xét:
 - Privacy – quyền riêng tư.
 - Latency – độ trễ.
 - Device – thiết bị triển khai.
 - Connectivity – kết nối mạng.
 - Cost – chi phí.
 - Legal / ethical constraints – Những ràng buộc pháp lý/đạo đức.
- Ràng buộc ảnh hưởng trực tiếp đến thiết kế hệ thống.

Key Hypotheses – Các giả thuyết quan trọng

- Khi định hình bài toán, ta đang đặt ra hai giả thuyết:
 - Target có thể dự đoán được từ input.
 - Dữ liệu đủ thông tin để học quan hệ input-output.
- Các giả thuyết này cần được kiểm chứng bằng mô hình.
- Không phải mọi bài toán đều giải được bằng ML.

Collect a Dataset – Thu thập dữ liệu

- Thu thập dữ liệu thường là phần khó, tốn thời gian và tốn chi phí nhất.
- Dataset cần phù hợp với input và target.
- Có thể cần:
 - Thu thập dữ liệu mới.
 - Gắn nhãn thủ công.
 - Làm sạch dữ liệu.
 - Kiểm tra chất lượng nhãn.
- Dataset tốt là tài sản quan trọng của dự án ML.

Data Annotation – Gắn nhãn dữ liệu

- Supervised learning cần input và target.
- Target thường đến từ annotation.
- Các lựa chọn annotation:
 - Tự gắn nhãn.
 - Dùng crowdsourcing.
 - Thuê công ty chuyên gắn nhãn.
 - Dùng chuyên gia lĩnh vực.
- Chất lượng annotation quyết định chất lượng model.

Representative Data – Dữ liệu đại diện

- Dữ liệu train phải giống dữ liệu production.
- Nếu training data khác production data, model có thể thất bại.
- Cần thu thập dữ liệu từ môi trường sử dụng thật nếu có thể.
- Tránh dùng dữ liệu đẹp, sạch nhưng không thực tế.
- Đây là nguyên tắc quan trọng khi xây dataset.

Concept Drift – Sự trôi khái niệm

- Concept drift xảy ra khi dữ liệu production thay đổi theo thời gian.
- Khi phân phối dữ liệu đổi, performance giảm dần.
- Gặp nhiều trong:
 - Recommendation.
 - Fraud detection.
 - User-generated content.
 - Text classification.
- Cần liên tục thu thập dữ liệu và retrain model.

Sampling Bias – Thiên lệch lấy mẫu

- Sampling bias xảy ra khi dữ liệu thu thập không đại diện cho tổng thể.
- Dẫn đến kết luận sai hoặc model sai.
- Nguyên nhân:
 - Cách thu thập dữ liệu lệch.
 - Nhóm người dùng không đại diện.
 - Thiếu dữ liệu từ một số nhóm.
- Cần kiểm tra cách dữ liệu được tạo ra.

Understand Your Data – Hiểu dữ liệu

- Không nên xem dataset như “hộp đen”.
- Cần khám phá dữ liệu trước khi train:
 - Xem mẫu ảnh / text.
 - Vẽ histogram.
 - Kiểm tra missing values.
 - Kiểm tra class imbalance.
 - Kiểm tra target leakage.
- Mục tiêu: hiểu dữ liệu có vấn đề gì trước khi modeling.


Choose a Measure of Success

Chọn thước đo thành công

- Muốn tối ưu điều gì thì phải đo được điều đó.
- Metric phải phù hợp với mục tiêu dự án.
- Một số metric phổ biến:
 - Accuracy.
 - Precision.
 - Recall.
 - ROC AUC.
 - Weighted accuracy.
 - Custom metric.
- Metric kỹ thuật nên liên hệ với mục tiêu kinh doanh.

DEEP LEARNING

NỀN TẢNG LÝ THUYẾT CÁC MÔ HÌNH HỌC SÂU



Develop a Model
Phát triển mô hình

Develop a Model – Phát triển mô hình

- Sau khi hiểu bài toán và dữ liệu, bắt đầu phát triển model.
- Các bước chính:
 - Prepare the data.
 - Choose evaluation protocol.
 - Beat a baseline.
 - Scale up to overfit.
 - Regularize and tune.
- Mục tiêu: đạt generalization tốt trên dữ liệu chưa thấy.

Prepare the Data – Chuẩn bị dữ liệu

- Deep learning thường không nhận raw data trực tiếp.
- Các bước chuẩn bị:
 - Vectorization.
 - Normalization.
 - Handling missing values.
 - Feature engineering nếu cần.
- Dữ liệu phải phù hợp để neural network xử lý.

Vectorization – Vector hóa dữ liệu

- Vectorization là chuyển dữ liệu thành vector/tensor.
- Neural network thường nhận:
 - Tensor số thực.
 - Một số trường hợp là tensor số nguyên hoặc chuỗi.
- Ví dụ:
 - Text → integer sequence / one-hot vector.
 - Image → pixel tensor.
 - Tabular data → feature matrix.
- Đây là bước đầu tiên để model đọc được dữ liệu.

Data Normalization – Chuẩn hóa dữ liệu

- Chuẩn hóa dữ liệu là biến đổi dữ liệu đầu vào về một thang đo phù hợp để mô hình học ổn định hơn, nhanh hơn và tránh việc feature có giá trị lớn “áp đảo” feature khác.
- Dữ liệu nên có hai tính chất sau:
 - Có giá trị nhỏ — Thông thường, hầu hết các giá trị nên nằm trong $[0-1]$.
 - Đồng nhất — Tất cả feature nên có giá trị trong cùng một phạm vi.
- Cách chuẩn hóa phổ biến:
 - Đưa giá trị về khoảng $0-1$. Hoặc:
 - Chuẩn hóa mean = 0 và standard deviation = 1.

Handling Missing Values – Xử lý giá trị thiếu

- Missing values thường xuất hiện trong dữ liệu thực tế.
- Với feature categorical:
 - Có thể tạo category “missing”.
- Với feature numerical:
 - Không nên tùy tiện điền 0.
 - Có thể dùng mean hoặc median.
 - Có thể dùng model khác để dự đoán giá trị thiếu.
- Cần train model với tình huống missing nếu production có missing.

Choose an Evaluation Protocol

Chọn quy trình đánh giá

- Mục tiêu đánh giá: ước lượng performance trên dữ liệu production.
- Ba quy trình phổ biến:
 - Holdout validation.
 - K-fold cross-validation.
 - Iterated K-fold validation.
- Chọn tùy theo lượng dữ liệu và độ tin cậy cần thiết.
- Validation set phải đại diện cho production data.

Beat a Baseline – Vượt qua baseline

- Mục tiêu ban đầu: đạt statistical power.
- Model nhỏ phải vượt qua baseline đơn giản.
- Cần tập trung vào:
 - Feature engineering.
 - Architecture priors.
 - Training configuration.
- Nếu không vượt baseline, cần xem lại bài toán hoặc dữ liệu.

Choosing Loss Function – Chọn hàm mất mát

- Loss cần:
 - Tính được trên mini-batch.
 - Khả vi để backpropagation.

Problem type	Last-layer activation	Loss function
Binary classification	sigmoid	binary_crossentropy
Multiclass, single-label classification	softmax	categorical_crossentropy
Multiclass, multilabel classification	sigmoid	binary_crossentropy

Scale Up – Develop a Model That Overfits

Tăng quy mô để mô hình quá khớp

- Sau khi vượt baseline, cần kiểm tra model có đủ capacity không.
- Cách làm model overfit:
 - Thêm layers.
 - Tăng số units / parameters.
 - Train nhiều epochs hơn.
- Quan sát training loss và validation loss.
- Khi validation performance giảm, model đã overfit.

Regularize and Tune

Điều chuẩn và tinh chỉnh mô hình

- Mục tiêu: tối đa hóa generalization.
- Các cách thử:
 - Thay đổi kiến trúc.
 - Thêm hoặc bớt layers.
 - Dùng dropout.
 - Dùng L1 / L2 regularization.
 - Tuning learning rate, batch size, số units.
 - Cải thiện dữ liệu hoặc feature.
- Lặp lại train → validate → chỉnh sửa.


Avoid Overfitting to Validation

Tránh quá khớp với dữ liệu xác thực

- Tuning quá nhiều lần trên validation set có thể gây leakage.
- Model không train trực tiếp trên validation data nhưng vẫn “học” từ phản hồi validation.
- Khi đó validation score không còn đáng tin cậy.
- Sau khi chọn model:
 - Train final model trên training + validation.
 - Đánh giá một lần cuối trên test set.
- Nếu test score thấp hơn nhiều, cần xem lại evaluation protocol.

DEEP LEARNING

NỀN TẢNG LÝ THUYẾT CÁC MÔ HÌNH HỌC SÂU



Deploy the Model Triển khai mô hình

Deploy the Model – Triển khai mô hình

- Khi model vượt qua đánh giá cuối trên test set, bắt đầu triển khai.
- Deployment không chỉ là lưu file model.
- Cần:
 - Giải thích kết quả cho stakeholder.
 - Chọn môi trường inference.
 - Tối ưu model.
 - Theo dõi performance.
 - Bảo trì và retrain.
- Model bắt đầu “đời sống sản phẩm”.

Explain Your Model to Stakeholders

Giải thích mô hình cho các bên liên quan

- Cần đặt kỳ vọng đúng trước khi launch.
- Không nên chỉ nói “model đạt 98% accuracy”.
- Nên giải thích bằng:
 - False positive.
 - False negative.
 - Số trường hợp cần review thủ công.
 - Tác động đến mục tiêu kinh doanh.
- Cần thảo luận threshold và trade-off.

Ship an Inference Model

Vận chuyển mô hình suy luận

- Production model thường khác training model.
- Inference chỉ dùng để dự đoán, không dùng để train.
- Cần cân nhắc:
 - Ngôn ngữ / nền tảng production.
 - Tốc độ phản hồi.
 - Memory footprint.
 - Bảo mật dữ liệu.
 - Khả năng tích hợp.
- Có thể export model sang format phù hợp.

Deployment as REST API

Triển khai bằng REST API

- Model chạy trên server hoặc cloud.
- Ứng dụng gửi request và nhận prediction.
- Phù hợp khi:
 - Có internet ổn định.
 - Không yêu cầu latency quá thấp.
 - Dữ liệu không quá nhạy cảm.
 - Cần scale tập trung.
- Công cụ ví dụ: TensorFlow Serving.

Deployment on Device or Browser

Triển khai trên thiết bị hoặc trình duyệt

- Model có thể chạy trực tiếp trên:
 - Smartphone.
 - Embedded device.
 - Browser.
 - Desktop JavaScript app.
- Phù hợp khi:
 - Cần latency thấp.
 - Cần offline.
 - Dữ liệu nhạy cảm.
 - Muốn giảm server cost.
- Công cụ ví dụ:
 - TensorFlow Lite.
 - TensorFlow.js.

Inference Model Optimization

Tối ưu mô hình suy luận

- Tối ưu inference quan trọng khi có ràng buộc:
 - Memory.
 - Power.
 - Latency.
 - Device capability.
- Hai kỹ thuật phổ biến:
 - Weight pruning.
 - Weight quantization.
- Mục tiêu: giảm kích thước và tăng tốc model.
- Luôn có trade-off giữa accuracy và efficiency.

Monitor and Maintain the Model

Giám sát và bảo trì mô hình

- Sau deployment, cần tiếp tục theo dõi:
 - Model performance.
 - Production data.
 - Business metrics.
 - Failure cases.
 - User feedback.
- Có thể dùng A/B testing.
- Cần audit thủ công nếu có thể.
- Model cần được retrain khi dữ liệu thay đổi.

Chapter Summary – Tổng kết chương

- Quy trình ML gồm 3 giai đoạn lớn:
 - Define the task.
 - Develop a model.
 - Deploy the model.
- Cần bắt đầu từ bài toán, không bắt đầu từ model.
- Dữ liệu đại diện và metric phù hợp rất quan trọng.
- Model cần vượt baseline, overfit được, rồi regularize.
- Production model cần được giám sát và bảo trì liên tục.

