

Natural Language Processing (AI408DV01)

Bài tập thực hành cá nhân – Tuần 01

Name:	Nguyễn Phúc Minh Châu
Student ID:	22302421
Deadline:	16/03/2026 - 23/03/2026
File name format:	AI301DV01-Lab-01-22302421.pdf

A. Chuẩn bị

- Đọc kỹ slide bài giảng **Introduction**
- [1] **Chapter 1, 2**. Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta, and Harshit Surana, *Practical Natural Language Processing*. O'Reilly, 2020.

B. Câu hỏi lý thuyết

Bài tập 1.

- Sinh viên đọc tài liệu [1] (xem bước chuẩn bị).
- Trình bày các giai đoạn (stages) chính của một Quy trình Xử lý ngôn ngữ tự nhiên tổng quát (Generic NLP pipeline).

Quy trình Xử lý ngôn ngữ tự nhiên (NLP pipeline) tổng quát là một chuỗi các bước xử lý văn bản có hệ thống nhằm xây dựng và triển khai bất kỳ mô hình NLP nào. Một quy trình điển hình bao gồm 8 giai đoạn chính sau đây:

1. Thu thập dữ liệu (Data acquisition)

Đây là bước đầu tiên để thu thập các nguồn dữ liệu văn bản liên quan đến bài toán cần giải quyết.

2. Làm sạch văn bản (Text cleaning)

Dữ liệu văn bản thu thập được thường không sạch và chứa nhiều nhiễu. Giai đoạn này tập trung vào việc trích xuất văn bản thô bằng cách loại bỏ các thông tin không cần thiết như thẻ đánh dấu (markup), siêu dữ liệu (metadata), các thành phần HTML hoặc mã JavaScript, và chuyển đổi văn bản sang định dạng mã hóa yêu cầu.

3. Tiền xử lý (Pre-processing)

Văn bản sau khi làm sạch cần được chuẩn hóa sang dạng mà các thuật toán có thể xử lý hiệu quả. Các bước này bao gồm:

- Các bước cơ bản: Phân đoạn câu (sentence segmentation), tách từ (word tokenization).
- Các bước phổ biến: Loại bỏ từ dừng (stop words), đưa từ về dạng gốc (stemming và lemmatization), xóa chữ số/dấu câu, chuyển về chữ thường
- Xử lý nâng cao: Gán nhãn từ loại (POS tagging), phân tích cú pháp (parsing), giải quyết đồng tham chiếu (coreference resolution)

4. Kỹ thuật đặc trưng (Feature engineering)

Giai đoạn này chuyển đổi dữ liệu văn bản thô sang định dạng số (vectors) mà máy tính có thể hiểu được. Trong NLP truyền thống, các đặc trưng này thường được thiết kế thủ công dựa trên kiến thức chuyên môn (như Bag-of-Words, TF-IDF), trong khi các mô hình Học sâu (Deep Learning) có thể học các đặc trưng (embeddings) một cách tự động.

5. Mô hình hóa (Modeling)

Dựa trên dữ liệu và các đặc trưng đã trích xuất, bằng cách xây dựng các mô hình để thực hiện nhiệm vụ NLP cụ thể. Thông thường, quy trình bắt đầu bằng các phương pháp phỏng đoán đơn giản (heuristics), sau đó tiến đến xây dựng các mô hình Học máy hoặc Học sâu phức tạp hơn để cải thiện hiệu suất.

6. Đánh giá (Evaluation)

Mô hình cần được đo lường độ chính xác và hiệu quả trên dữ liệu chưa từng thấy (unseen data). Các chỉ số đánh giá sẽ thay đổi tùy theo nhiệm vụ cụ thể, ví dụ như Accuracy, Precision, Recall, F1-score cho các bài toán phân loại văn bản.

7. Triển khai (Deployment)

Khi mô hình đạt hiệu suất mong muốn, nó sẽ được tích hợp vào một hệ thống phần mềm lớn hơn trong môi trường thực tế. Mô hình thường được triển khai dưới dạng một web service (dịch vụ web) để các thành phần khác của ứng dụng có thể gửi dữ liệu đầu vào và nhận kết quả dự đoán

8. Giám sát và cập nhật mô hình (Monitoring and model updating)

Sau khi triển khai, hiệu suất của mô hình cần được theo dõi liên tục để phát hiện các vấn đề như thay đổi trong mẫu dữ liệu thực tế (covariate shift). Việc thường xuyên giám sát và cập nhật mô hình với dữ liệu mới là cực kỳ quan trọng để duy trì chất lượng hệ thống

Lưu ý: Trong thực tế, quy trình này không diễn ra theo một đường thẳng cố định mà thường là một chu trình lặp đi lặp lại với nhiều lần quay lại các bước trước đó để tinh chỉnh và tối ưu hóa

Bài tập 2.

- Chọn ra 2-3 kỹ thuật cụ thể và các thư viện (python library) sử dụng trong mỗi giai đoạn (stage) của NLP pipeline.

1. Thu thập dữ liệu (Data Acquisition)

Kỹ thuật: Trích xuất dữ liệu từ web (Web Scraping), sử dụng các tập dữ liệu công khai, hoặc các kỹ thuật tăng cường dữ liệu (Data Augmentation) như thay thế từ đồng nghĩa hoặc dịch ngược (back-translation).

Thư viện: BeautifulSoup hoặc Scrapy (để thu thập dữ liệu web), Snorkel (để tạo dữ liệu huấn luyện tự động bằng phương pháp giám sát yếu), và NLPAug (để tăng cường dữ liệu văn bản).

2. Làm sạch văn bản (Text Cleaning)

Kỹ thuật: Loại bỏ thẻ HTML/văn bản rác, chuẩn hóa Unicode và sửa lỗi chính tả (Spelling correction).

Thư viện: BeautifulSoup (để gỡ bỏ các thẻ đánh dấu), regex (thư viện Python nâng cao để xử lý các mẫu văn bản phức tạp), và pyenchant hoặc TextBlob (hỗ trợ kiểm tra và sửa lỗi chính tả).

3. Tiền xử lý (Pre-processing)

Kỹ thuật: Tách từ (Tokenization), loại bỏ từ dừng (Stop words removal) và gán nhãn từ loại (POS Tagging).

Thư viện: NLTK (thư viện nền tảng cho các bước tách câu, tách từ cơ bản), spaCy (thư viện NLP công nghiệp mạnh mẽ để xử lý lemmatization, POS tagging đồng thời) và textacy (xây dựng trên spaCy để thực hiện các nhiệm vụ như trích xuất cụm từ).

4. Kỹ thuật đặc trưng (Feature Engineering)

Kỹ thuật: Bag-of-Words (BoW), TF-IDF (Term Frequency–Inverse Document Frequency), và Nhúng từ/câu (Word/Sentence Embeddings).

Thư viện: scikit-learn (cung cấp CountVectorizer và TfidfVectorizer), Gensim (chuyên dùng cho các mô hình nhúng như Word2vec, FastText) và Sentence Transformers (để tạo các vector biểu diễn ngữ nghĩa cho câu).

5. Mô hình hóa (Modeling)

Kỹ thuật: Các thuật toán Học máy truyền thống (như Naive Bayes, SVM, Logistic Regression) và các kiến trúc Học sâu (Deep Learning) (như CNN, LSTM, hoặc Transformers/BERT).

Thư viện: scikit-learn (cho học máy truyền thống), Transformers (Hugging Face) (thư viện tiêu chuẩn cho các mô hình dựa trên Transformer như BERT, GPT), và Keras / TensorFlow hoặc PyTorch (để xây dựng các mạng nơ-ron tùy chỉnh).

6. Đánh giá (Evaluation)

Kỹ thuật: Tính toán các chỉ số như Accuracy, Precision, Recall, F1-score và sử dụng Ma trận nhầm lẫn (Confusion Matrix) để phân tích lỗi.

Thư viện: scikit-learn (module metrics cung cấp hầu hết các chỉ số đánh giá) và Evaluate (Hugging Face) (thư viện chuyên biệt để đánh giá các mô hình học máy hiện đại).

7. Triển khai (Deployment)

Kỹ thuật: Đóng gói mô hình (Model packaging), xây dựng Web Service/API và Container hóa (Containerization).

Thư viện: Flask hoặc Django (để tạo các API phục vụ dự đoán trực tuyến), và Docker (để đóng gói môi trường chạy mô hình).

8. Giám sát và cập nhật mô hình (Monitoring and Updating)

Kỹ thuật: Theo dõi Sự thay đổi phân phối dữ liệu (Covariate shift), phân tích lỗi thông qua các công cụ diễn giải mô hình (Interpretability) và quản lý phiên bản dữ liệu/mô hình.

Thư viện: TensorFlow Model Analysis (để theo dõi hiệu suất mô hình trong sản xuất), DVC (Data Version Control) (để quản lý phiên bản dữ liệu và mô hình) và LIT-NLP (công cụ để trực quan hóa và diễn giải hành vi của các mô hình ngôn ngữ).

Bài tập 3.

- Trình bày các tính năng chính của thư viện NLTK và spaCy.

1. Thư viện NLTK (Natural Language Toolkit)

NLTK là một thư viện nền tảng, thường được sử dụng trong giáo dục và nghiên cứu nhờ tính mô-đun cao và tập hợp phong phú các thuật toán. Các tính năng chính bao gồm:

- **Tách từ và tách câu (Tokenization):** Cung cấp các bộ tách câu (sent_tokenize) và tách từ (word_tokenize) dựa trên các tiêu chuẩn như Penn Treebank. Nó cũng có bộ tách từ chuyên biệt cho mạng xã hội (TweetTokenizer) để xử lý hashtag và biểu tượng cảm xúc
- **Cung cấp tài nguyên ngôn ngữ:** Tích hợp sẵn quyền truy cập vào nhiều ngữ liệu (corpora) và từ điển như WordNet, cho phép khai thác các quan hệ đồng nghĩa, hyponym và meronym.

- **Tiền xử lý văn bản:** Hỗ trợ loại bỏ từ dừng (stop words), gán nhãn từ loại (POS tagging) và các thuật toán stemming (như Porter Stemmer) để đưa từ về dạng gốc
- **Phân tích ngữ cảnh:** Tính năng concordance view giúp hiển thị các ngữ cảnh xung quanh một từ cụ thể trong ngữ liệu
- **Huấn luyện không giám sát:** Cung cấp bộ tách câu Punkt có khả năng huấn luyện không giám sát trên tập dữ liệu mục tiêu để học các quy tắc đặc thù của miền

2. Thư viện spaCy

spaCy được mệnh danh là thư viện "Industrial-strength" (sức mạnh công nghiệp), được thiết kế để tối ưu hóa hiệu suất trong các hệ thống triển khai thực tế. Các tính năng chính bao gồm:

- **Quy trình xử lý tích hợp (Integrated Pipeline):** Cho phép thực hiện đồng thời nhiều tác vụ như tách từ, gán nhãn POS, lemmatization và nhận dạng thực thể tên (NER) chỉ trong một lần xử lý văn bản
- **Nhận dạng thực thể tên (NER) mạnh mẽ:** Sử dụng các mô hình nơ-ron tiên tiến (state-of-the-art) để xác định các thực thể như người, tổ chức, vị trí, tiền tệ và ngày tháng với độ chính xác cao
- **Lemmatization chất lượng cao:** Khác với stemming của NLTK, spaCy thực hiện lemmatization (tìm từ nguyên) dựa trên phân tích ngôn ngữ học sâu sắc, giúp trả về dạng gốc chính xác về mặt từ vựng (ví dụ: "better" trở thành "well")
- **Hỗ trợ Vector và Embeddings:** Khả năng tạo ra các vector biểu diễn ngữ nghĩa cho từ hoặc cả đoạn văn bản bằng cách trung bình hóa các vector từ, phục vụ cho các bài toán so sánh độ tương đồng
- **So khớp dựa trên quy tắc (Rule-based Matching):** Cung cấp công cụ EntityRuler và bộ so khớp quy tắc nâng cao cho phép kết hợp các mô hình học máy với các mẫu (patterns) do người dùng định nghĩa

- **Xử lý ngoại lệ ngôn ngữ:** Tokenizer của spaCy có khả năng xử lý các trường hợp ngoại lệ đặc thù của ngôn ngữ (ví dụ: giữ nguyên "N.Y." thay vì tách ra)

Bài tập 4.

- Tìm hiểu và trình bày một số công cụ, thư viện Xử lý ngôn ngữ tự nhiên Tiếng Việt phổ biến hiện nay.

Một trong những bộ công cụ toàn diện và phổ biến nhất dành cho Tiếng Việt là **VnCoreNLP**. VnCoreNLP cung cấp giải pháp cho nhiều tác vụ NLP quan trọng như tách từ (word segmentation), gán nhãn từ loại (POS tagging), phân tích cú pháp phụ thuộc và nhận dạng thực thể tên (NER). Được đánh giá là bộ tách từ có độ chính xác cao và tốc độ nhanh cho Tiếng Việt.

Ngoài ra còn có các thư viện phổ biến khác như underthesea, PyVi hay Vitk. Các công cụ này thường được xây dựng để giải quyết các vấn đề về chuẩn hóa văn bản và xử lý Unicode, vốn là những bước tiền xử lý cực kỳ quan trọng đối với dữ liệu Tiếng Việt.