

Natural Language Processing (AI408DV01)

Bài tập thực hành cá nhân – Tuần 03

Name:	Nguyễn Phúc Minh Châu
Student ID:	22302421
Deadline:	30/03/2026 - 06/04/2026
File name format:	AI301DV01-Lab-03-22302421.pdf

A. Chuẩn bị

- Đọc kỹ slide bài giảng **Word Tokenization** (phần **Regular Expression**)
- [1] Chapter 2. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
- [3] Chapter 2. Jay Alamar and Maarten Grootendorst, *Hands-On Large Language Models*. O'Reilly, 2024.

B. Câu hỏi lý thuyết

Bài tập 1.

Viết biểu thức chính quy (regular expression) cho các ngôn ngữ sau:

- Tập hợp tất cả các chuỗi chữ cái (alphabetic strings): $\mathbf{r}^{\text{"[A-Za-z]*$"$
- Tập hợp tất cả các chuỗi chữ cái viết thường (lower case alphabetic strings) kết thúc bằng $\mathbf{b}$: $\mathbf{r}^{\text{"[a-z]*b$"$
- Tập hợp tất cả các chuỗi từ 2 chữ cái $\mathbf{a}$, $\mathbf{b}$ sao cho mỗi $\mathbf{a}$ được đứng ngay trước và ngay sau bởi $\mathbf{b}$: $\mathbf{r}^{\text{"b+(ab+)*$"$

Bài tập 2.

Viết biểu thức chính quy cho các ngôn ngữ sau. “**Từ**” (word) ở đây được hiểu là một chuỗi ký tự chữ cái được phân tách với các từ khác bởi khoảng trắng (whitespace), dấu câu (relevant punctuation), xuống dòng (line breaks), v.v.

- a. Tập hợp tất cả các chuỗi có hai từ lặp lại liên tiếp (two consecutive repeated words) (ví dụ: “Humbert Humbert” và “the the” nhưng không phải “the bug” hoặc “the big bug”);

$r"^\backslash\mathbf{b}([A-Za-z]^+)\backslash\mathbf{W}+\backslash\mathbf{1}\backslash\mathbf{b}"$: Khớp với một từ, lưu vào nhóm 1, sau đó là các ký tự không phải chữ cái (khoảng trắng, dấu câu) và lặp lại chính xác từ đó bằng tham chiếu ngược **$\backslash\mathbf{1}$** .

- b. Tất cả các chuỗi bắt đầu bằng một số nguyên ở đầu dòng và kết thúc bằng một từ ở cuối dòng (all strings that start at the beginning of the line with an integer and that end at the end of the line with a word);

$r"^\wedge\backslash\mathbf{d}+.*\backslash\mathbf{b}[A-Za-z]^+\backslash\mathbf{b}\$"$: Sử dụng neo **$\wedge$** để bắt đầu bằng một số nguyên (**$\backslash\mathbf{d}+$**), theo sau là nội dung bất kỳ (**$.*$**) và kết thúc bằng neo **$\$$** cho một từ đứng cuối dòng.

- c. Tất cả các chuỗi có cả từ “***grotto***” và từ “***raven***” (ví dụ: các từ như “grottos” chỉ chứa từ “grotto” không thỏa định nghĩa);

$r"^\wedge(?:=.*\backslash\mathbf{b}grotto\backslash\mathbf{b})(?:=.*\backslash\mathbf{b}raven\backslash\mathbf{b}).*\$"$: Sử dụng cơ chế lookahead (**$(?:=...)$**) để đảm bảo chuỗi chứa cả hai từ độc lập “***grotto***” và “***raven***” ở bất kỳ vị trí nào mà không quan tâm đến thứ tự

- d. Viết một mẫu (**pattern**) để lấy từ đầu tiên trong một câu tiếng. Xử lý dấu câu (punctuation).

$r"^\wedge\backslash\mathbf{W}^*([A-Za-z]^+)\backslash\mathbf{b}"$: Bắt đầu dòng, bỏ qua các ký tự không phải chữ cái đầu câu (nếu có), sau đó dùng dấu ngoặc đơn để lưu từ đầu tiên (chuỗi chữ cái) vào một thanh ghi (capture group).