

Natural Language Processing (AI408DV01)

Bài tập thực hành cá nhân – Tuần 05

Name:	Nguyễn Phúc Minh Châu
Student ID:	22302421
Deadline:	13/04/2026 - 20/04/2026
File name format:	AI301DV01-Lab-05-22302421.pdf

A. Chuẩn bị

- Đọc kỹ slide bài giảng Part-of-Speech Tagging (POS)
- [1] Chapter 17. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.

B. Câu hỏi lý thuyết

Bài tập 1. (xem file đính kèm [17_Sequence Labeling for Parts of Speech and Named Entities.pdf](#))

Trình bày Conditional Random Fields (CRFs):

Conditional Random Fields (**CRFs**), đặc biệt là phiên bản linear-chain CRF, là một mô hình chuỗi phân biệt (discriminative sequence model) được sử dụng rộng rãi trong xử lý ngôn ngữ tự nhiên để giải quyết các bài toán như gán nhãn từ loại (POS tagging) hoặc nhận dạng thực thể có tên (NER).

a. Các tính năng của trình gán nhãn (tagger) CRF

Khác với các mô hình tạo sinh (generative) như HMM vốn khó kết hợp nhiều nguồn thông tin, CRF cho phép tích hợp các đặc trưng tùy ý một cách linh hoạt.

- **Đặc trưng cục bộ (Local Features):** Một đặc trưng f_k tại vị trí i trong chuỗi có thể phụ thuộc vào nhãn hiện tại (y_i), nhãn ngay trước đó (y_{i-1}), và toàn bộ chuỗi quan sát đầu vào X .
- **Khuôn mẫu đặc trưng (Feature Templates):** Thay vì tạo đặc trưng thủ công, các nhà thiết kế sử dụng khuôn mẫu để tự động sinh ra

hàng ngàn đặc trưng từ dữ liệu huấn luyện. Ví dụ: một khuôn mẫu có thể kết hợp "từ hiện tại là back" và "nhân hiện tại là VB".

- **Xử lý từ chưa biết (Unknown Word Features):** CRF cực kỳ mạnh mẽ trong việc xử lý các từ không có trong từ điển nhờ các đặc trưng hình thái học:
 - **Hình dạng từ (Word Shape):** Ánh xạ từ thành các chuỗi trừu tượng (ví dụ: "I.M.F." thành "X.X.X.") để nhận diện các quy luật viết hoa hoặc ký hiệu.
 - **Tiền tố và Hậu tố:** Kiểm tra các phần đầu/cuối của từ (như "-ed" thường là động từ quá khứ).
- **Sử dụng ngữ cảnh rộng:** Đặc trưng có thể nhìn vào các từ lân cận (từ đứng trước, đứng sau hoặc xa hơn) để đưa ra quyết định gán nhãn chính xác hơn.

b. Cơ chế suy luận và huấn luyện CRFs

+ Cơ chế suy luận (Inference)

Mục tiêu của suy luận là tìm chuỗi nhãn $\hat{Y}$ có xác suất cao nhất cho một chuỗi quan sát X cho trước. Tương tự như trong HMM, CRF sử dụng thuật toán Viterbi để tìm kiếm chuỗi nhãn tối ưu một cách hiệu quả.

Trong CRF, thay vì nhân các xác suất chuyển tiếp và xác suất phát xạ, thuật toán Viterbi sẽ tính toán dựa trên tổng trọng số của các đặc trưng. Tại mỗi bước thời gian t cho trạng thái j , giá trị Viterbi được tính bằng cách lấy cực đại của tổng giá trị Viterbi trước đó cộng với tổng các trọng số đặc trưng tại vị trí hiện tại.

+ Cơ chế huấn luyện (Training)

Huấn luyện CRF là quá trình học các trọng số w_k cho mỗi đặc trưng f_k sao cho mô hình giải thích tốt nhất dữ liệu đã được gán nhãn thủ công. Sử dụng phương pháp ước lượng hợp lý cực đại có điều kiện (conditional maximum likelihood estimation), tương tự như trong hồi quy logistic. Trọng số được điều chỉnh để tối đa hóa log-likelihood của chuỗi nhãn đúng trên toàn bộ tập huấn luyện và sử dụng thuật toán Hạ giáng ngẫu nhiên (Stochastic Gradient Descent - SGD) để tối ưu hóa, cập nhật trọng số.

Để tính toán các đạo hàm cần thiết cho việc cập nhật trọng số một cách hiệu quả, CRF áp dụng một phiên bản mở rộng của thuật toán Forward-Backward từ HMM. Để tránh hiện tượng quá khớp (overfitting), các kỹ thuật điều chuẩn L1 hoặc L2 thường được áp dụng trong quá trình huấn luyện.

Bài tập 2.

Trình bày một số ứng dụng cụ thể của Gán nhãn từ loại (POS tagging)

- **Phân tích cú pháp (Parsing):** POS tagging giúp cải thiện việc phân tích cấu trúc câu bằng cách xác định vai trò ngữ pháp của từ, từ đó dự đoán các từ liên kết xung quanh (ví dụ: danh từ thường đi sau định từ).
- **Dịch máy (Machine Translation):** Hỗ trợ việc sắp xếp lại thứ tự từ ngữ giữa các ngôn ngữ có cấu trúc khác nhau, chẳng hạn như vị trí của tính từ so với danh từ trong tiếng Việt và tiếng Anh.
- **Chuyển văn bản thành giọng nói (TTS):** Giúp hệ thống biết cách phát âm chính xác các từ viết giống nhau nhưng khác từ loại (như "record" là danh từ hay động từ) và dự đoán các ranh giới ngữ điệu trong câu.
- **Phân tích cảm xúc (Sentiment Analysis):** Việc phân biệt tính từ với các từ loại khác giúp hệ thống nhận diện tốt hơn các sắc thái biểu cảm và thái độ của người viết.
- **Nhận dạng thực thể có tên (NER):** Là bước đầu tiên để xác định các thực thể như tên người, tổ chức hay địa danh (ví dụ: phân biệt "Washington" là tên người hay tên thành phố).
- **Nghiên cứu ngôn ngữ học:** Hỗ trợ kiểm soát từ loại khi đo lường sự thay đổi nghĩa của từ hoặc nghiên cứu cách tạo ra các từ mới trong ngôn ngữ.
- **Xử lý dấu câu:** Giúp phân biệt dấu chấm cuối câu với dấu chấm trong các từ viết tắt (như "Prof.") dựa trên ngữ cảnh từ loại xung quanh.

Bài tập 3.

Tìm hiểu và demo minh họa 2 trình gán nhãn từ loại (POS tagger) dành cho tiếng Anh.

Bài tập 4.

Tìm hiểu và demo minh họa 2 trình gán nhãn từ loại (POS tagger) dành cho tiếng Việt.

Bài tập 5. (***)

Xây dựng một bộ gán nhãn từ loại đơn giản sử dụng Hidden Markov Model (bigram HMM tagger).

- Cần bộ ngữ liệu đã gán nhãn (part-of-speech-tagged corpus)
- Chia ngữ liệu thành 2 tập: huấn luyện (training set) và tập kiểm thử (test set)
- Tính các xác suất chuyển trạng thái và xác suất quan sát (transition and observation probabilities)
- Triển khai thuật toán Viterbi
- Chạy thuật toán trên tập kiểm thử và ghi nhận tỷ lệ lỗi (error rate), F1-scores...