

Natural Language Processing (AI408DV01)

Bài tập thực hành cá nhân – Tuần 06

Name:	Nguyễn Phúc Minh Châu
Student ID:	22302421
Deadline:	20/04/2026 - 27/04/2026
File name format:	AI301DV01-Lab06-22302421.pdf

A. Chuẩn bị

- Đọc kỹ file/slide bài giảng N-gram Language Models, Embeddings
- [1] Chapter 3, 5. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
- [3] Chapter 2. Jay Alamar and Maarten Grootendorst, *Hands-On Large Language Models*. O'Reilly, 2024.
- [5] Chapter 3. Lewis Tunstall, Leandro von Werra, Thomas Wolf, and Aurélien Géron, *Natural Language Processing with Transformers, Revised edition*. O'Reilly, 2022.

B. Câu hỏi lý thuyết

Bài tập 1.

- Trình bày phương pháp Word2vec embeddings.

Word2vec là một phương pháp biểu diễn ngôn ngữ được công bố vào năm 2013 bởi Tomas Mikolov và các cộng sự tại Google. Word2vec cho phép chuyển đổi các từ thành các vector số thực dày đặc (dense vectors) mang ý nghĩa, ngữ nghĩa.

Word2vec dựa trên giả thuyết phân bố (distributional hypothesis): các từ xuất hiện trong những bối cảnh tương tự nhau thường sẽ có ý nghĩa gần nhau. Mục tiêu của Word2vec là học các biểu diễn từ tĩnh (static embeddings) sao cho các từ có liên quan về mặt ngữ nghĩa sẽ nằm gần nhau trong không gian vector đa chiều. Gồm hai thuật toán huấn luyện chính:

- Skip-gram: Dự báo các từ bối cảnh (context words) xung quanh dựa trên một từ mục tiêu (target word) cho trước.
- CBOW (Continuous Bag-of-Words): Ngược lại với Skip-gram, nó dự báo từ mục tiêu dựa trên các từ bối cảnh xung quanh.

Thuật toán Skip-gram kết hợp với kỹ thuật Lấy mẫu tiêu cực (Negative Sampling) để tối ưu hóa hiệu suất huấn luyện:

- **Chuyển đổi bài toán:** Thay vì dự báo xác suất của từ tiếp theo trong toàn bộ từ điển (vốn rất tốn kém chi phí tính toán), Word2vec chuyển đổi thành bài toán phân loại nhị phân: "Liệu hai từ này có phải là hàng xóm của nhau trong văn bản hay không?".
- **Ví dụ tích cực (Positive examples):** Là các cặp từ thực sự xuất hiện gần nhau trong một cửa sổ trượt (sliding window) nhất định (ví dụ: cửa sổ kích thước ± 2 đến ± 10 từ).
- **Ví dụ tiêu cực (Negative examples):** Là các cặp từ được tạo ra bằng cách ghép từ mục tiêu với các từ được chọn ngẫu nhiên từ từ điển mà không xuất hiện trong bối cảnh thực tế của nó.
- **Hàm mất mát và Tối ưu hóa:** Mô hình sử dụng hồi quy logistic và hàm sigmoid để tối ưu hóa các trọng số (chính là các vector embedding). Mục tiêu là tối đa hóa tích vô hướng (độ tương đồng) giữa các cặp từ tích cực và tối thiểu hóa tích vô hướng giữa các cặp từ mục tiêu với các mẫu tiêu cực. Quá trình này được thực hiện thông qua thuật toán hạ cực trị gradient ngẫu nhiên (Stochastic Gradient Descent).

Các vector Word2vec có kích thước cố định và dày đặc thường có từ 50 đến 1000 chiều, trong đó mỗi chiều là một số thực (khác với biểu diễn thưa - sparse representation như Bag-of-Words). Mỗi từ trong từ điển chỉ có duy nhất một vector đại diện, bất kể nó được dùng trong ngữ cảnh nào (ví dụ: từ "bank" trong "river bank" và "financial bank" sẽ có cùng một vector). Các vector này có khả năng nắm bắt các mối quan hệ tương quan (analogy).

Ví dụ:

$$\text{Vector}(\text{"King"}) - \text{Vector}(\text{"Man"}) + \text{Vector}(\text{"Woman"}) \approx \text{Vector}(\text{"Queen"})$$

Độ tương đồng giữa hai từ thường được tính bằng độ tương đồng cosine (cosine similarity) của hai vector đại diện.

Trong nghiên cứu và ứng dụng, Word2vec đóng vai trò cung cấp các đặc trưng (features) cho các tác vụ như phân loại văn bản, phân tích cảm xúc, hoặc gán nhãn từ loại. Word2vec có thể được áp dụng ngoài lĩnh vực văn bản, chẳng hạn như coi các danh sách bài hát (playlists) như các câu và các bài hát như các từ để xây dựng hệ thống gợi ý âm nhạc dựa trên sự xuất hiện đồng thời.

Bài tập 2.

- Trình bày và demo sử dụng embeddings cho hệ thống đề xuất bài hát tự động (Embeddings for Song Recommendation Systems)