

Natural Language Processing (AI408DV01)

Bài tập thực hành cá nhân – Tuần 09

Name:	Nguyễn Phúc Minh Châu
Student ID:	22302421
Deadline:	18/05/2026 - 25/05/2006
File name format:	AI301DV01-Lab-09-22302421.pdf

A. Chuẩn bị

- Đọc kỹ slide bài giảng **Semantics**
- [1] **Chapter 5**. Dan Jurafsky and James H. Martin, *Speech and Language Processing*, 3rd ed. Pearson, 2026.
 - o <https://web.stanford.edu/~jurafsky/slp3/>
 - o Embeddings: <https://web.stanford.edu/~jurafsky/slp3/5.pdf>
- [2] **Chapter 3**. Sowmya Vajjala, Bodhisattwa Majumder, Anuj Gupta, and Harshit Surana, *Practical Natural Language Processing*. O'Reilly, 2020.
- [3] **Chapter 2**. Jay Alammara and Maarten Grootendorst, *Hands-On Large Language Models*. O'Reilly, 2024.

B. Câu hỏi lý thuyết

Bài tập 1. (tham khảo Chapter 3 tài liệu [2])

Trình bày các kỹ thuật biểu diễn văn bản (text presentation) sau:

- TF-IDF
- Word2vec

Nêu ưu điểm và nhược điểm của từng kỹ thuật.

TF-IDF là một kỹ thuật vector hóa cơ bản nhằm định lượng tầm quan trọng của một từ (term) đối với một tài liệu cụ thể trong một tập hợp văn bản (corpus). Thay vì chỉ đếm số lần xuất hiện đơn thuần, TF-IDF gán trọng số cho từ dựa trên mức độ phổ biến của từ.

Trọng số TF-IDF là tích của hai chỉ số:

- **TF (Term Frequency)**: Đo lường tần suất từ xuất hiện trong tài liệu. Từ xuất hiện càng nhiều, TF càng cao

- **IDF (Inverse Document Frequency):** Đo lường mức độ quan trọng của từ trên toàn bộ tập dữ liệu. Những từ quá phổ biến (như "là", "và", "the") sẽ có chỉ số IDF thấp, trong khi những từ hiếm và mang tính đặc trưng sẽ có IDF cao

Ưu Điểm	Nhược Điểm
– Trực quan – Đơn giản – Lọc nhiễu tốt với cơ chế IDF giúp loại bỏ tác động của các từ dừng (stop words) không mang nhiều ý nghĩa ngữ nghĩa – Baseline hàng đầu cho các hệ thống truy vấn đơn giản	– Dữ liệu thưa (Sparsity) – Không nắm bắt ngữ nghĩa (không bắt nổi quan hệ, chia từ độc lập) – Không thể biểu diễn được những từ không xuất hiện trong tập huấn luyện – Do dựa trên mô hình Bag-of-Words, thứ tự và cấu trúc ngữ pháp của câu bị bỏ qua hoàn toàn

Word2vec được giới thiệu vào năm 2013, Word2vec là một trong những thành công đầu tiên trong việc nắm bắt ý nghĩa của văn bản dưới dạng các vector dày đặc (dense vectors) và thấp chiều (thường từ 50 đến 500 chiều). Thay vì đếm, nó sử dụng mạng thần kinh để dự đoán.

Word2vec dựa trên giả thuyết phân phối (distributional hypothesis): các từ xuất hiện trong cùng một ngữ cảnh thường có ý nghĩa tương tự nhau. Có hai kiến trúc chính là:

- **CBOW (Continuous Bag of Words):** Dự đoán từ mục tiêu dựa trên các từ ngữ cảnh xung quanh
- **Skip-gram:** Sử dụng một từ mục tiêu để dự đoán các từ ngữ cảnh xung quanh

Ưu Điểm	Nhược Điểm
– Vector có kích thước cố định và nhỏ, giúp các thuật toán học máy xử lý nhanh hơn và tránh hiện tượng quá khớp	– Mỗi từ chỉ có một đại diện vector duy nhất, không thay đổi theo ngữ cảnh (ví dụ: từ "bank" trong "financial bank" và "river")

(overfitting) – Nắm bắt quan hệ ngữ nghĩa bằng các từ có ý nghĩa tương đương sẽ nằm gần nhau trong không gian vector (ví dụ: King – Man + Woman $\approx$ Queen) – Khả năng tổng quát hóa tốt giữa các từ tương tự ngay cả khi chúng không xuất hiện cùng nhau thường xuyên trong một văn bản cụ thể	bank" sẽ có cùng một vector), gây ra sự mơ hồ về đa nghĩa. – Cần một lượng lớn văn bản để huấn luyện mô hình đạt độ chính xác cao – Huấn luyện mô hình từ đầu rất tốn kém thời gian và tài nguyên; các mô hình tiền huấn luyện thường có kích thước tệp rất lớn (vài GB) – Nếu một từ không xuất hiện trong từ điển huấn luyện, mô hình không thể tạo ra vector cho từ đó (trừ khi kết hợp các kỹ thuật subword như fastText)
---	--

Bài tập 2. (tham khảo Chapter 9, tài liệu [1])

Trình bày phương pháp biểu diễn BERT

BERT dựa trên kiến trúc Transformer, nhưng khác với mô hình Transformer nguyên bản (có cả Encoder và Decoder), BERT chỉ sử dụng chồng các khối Encoder.

- **Số lượng lớp:** Phiên bản BERT cơ bản (base) thường có 12 khối Encoder chồng lên nhau
- **Cơ chế tự chú ý (Self-attention):** Mỗi khối Encoder sử dụng cơ chế multi-head self-attention để cho phép mỗi từ trong câu "nhìn" vào tất cả các từ khác xung quanh nó đồng thời, từ đó xây dựng nên mối quan hệ ngữ nghĩa phức tạp

Để BERT có thể xử lý văn bản, dữ liệu đầu vào được biểu diễn qua các thành phần sau:

- **Tokenization (WordPiece):** BERT sử dụng thuật toán WordPiece để chia văn bản thành các đơn vị con (subwords), giúp giải quyết vấn đề từ ngoài từ điển (OOV)
- **Các Token đặc biệt:**
 - **[CLS] (Classification):** Luôn nằm ở đầu mỗi chuỗi đầu vào. Vectơ trạng thái cuối cùng của token này được dùng làm đại diện cho toàn bộ câu trong các tác vụ phân loại
 - **[SEP] (Separator):** Dùng để ngăn cách giữa hai câu hoặc đánh dấu điểm kết thúc của một đoạn văn
- **Sự kết hợp các Embedding:** Biểu diễn cuối cùng của mỗi token là tổng của ba loại embedding: Token Embeddings (giá trị của từ đó), Segmentation Embeddings (để phân biệt câu A và câu B), và Positional Embeddings (để mô hình biết vị trí của từ trong câu vì Transformer không xử lý tuần tự)

BERT được huấn luyện trước trên một lượng dữ liệu khổng lồ (như Wikipedia) thông qua hai nhiệm vụ học không giám sát chính:

- **Masked Language Modeling (MLM):** Mô hình sẽ che đi (mask) ngẫu nhiên một số từ trong câu và yêu cầu BERT dự đoán từ đó dựa vào ngữ cảnh của cả hai phía (trái và phải). Đây chính là đặc tính song phương (bidirectional) cốt lõi giúp BERT vượt trội hơn các mô hình chỉ đọc từ trái sang phải như GPT-1
- **Next Sentence Prediction (NSP):** BERT học cách hiểu mối quan hệ giữa hai câu bằng cách dự đoán xem câu B có thực sự là câu tiếp theo của câu A trong văn bản gốc hay không

Khác với các phương pháp biểu diễn tĩnh như Word2vec (nơi từ "bank" luôn có một vectơ duy nhất), BERT tạo ra các contextualized word embeddings. Điều này có nghĩa là cùng một từ "bank" sẽ có các biểu diễn vectơ khác nhau tùy thuộc vào việc nó xuất hiện trong ngữ cảnh "tài chính" hay "bờ sông".