

Natural Language Processing (AI408DV01)

Bài tập thực hành cá nhân – Tuần 10

Name:	Nguyễn Phúc Minh Châu
Student ID:	22302421
Deadline:	25/05/2025 - 01/06/2025
File name format:	AI301DV01-Lab-10-22302421.pdf

Bài tập 1. (xem file Named Entity Recognition_Alammar.pdf)

Trình bày quá trình tinh chỉnh mô hình BERT sẵn có cho bài toán NER (named-entity recognition)

- Mô tả quá trình
- Giải thích source code

(fine-tuning a pretrained BERT model specifically for NER)

=====

1. Mô Tả Quá Trình

Tinh chỉnh BERT cho NER là một bài toán phân loại ở cấp độ token (token-level classification), khác với phân loại văn bản (document classification) vốn chỉ gán một nhãn cho toàn bộ chuỗi.

Sử dụng một mô hình BERT (encoder-only) đã được huấn luyện trước (pretrained) làm nền tảng để trích xuất đặc trưng ngữ cảnh (contextual embeddings). Sau đó, một "đầu phân loại" (classification head) – thực chất là một mạng nơ-ron truyền thẳng (feedforward neural network) – được thêm vào phía trên mỗi token đầu ra của BERT.

Thay vì tổng hợp (pooling) tất cả các vector của token thành một vector đại diện cho câu (như dùng token [CLS]), trong NER, mô hình thực hiện dự báo độc lập cho mỗi token trong trình tự. Mỗi token sẽ được gán một nhãn thực thể (như Người,

Địa điểm, Tổ chức) hoặc nhãn "Không phải thực thể". Trong quá trình huấn luyện, cả tham số của mô hình BERT gốc và tham số của đầu phân loại đều được cập nhật đồng thời (jointly updated) điều này giúp mô hình học được cách biểu diễn ngôn ngữ đặc thù cho nhiệm vụ nhận dạng thực thể.

NER khó hơn các bài toán gán thẻ từ loại (POS tagging) vì một thực thể có thể gồm nhiều từ (ví dụ: "Marie Curie"). Do đó, chúng ta cần sử dụng hệ thống gán nhãn BIO (Begin-Inside-Outside) để xác định ranh giới thực thể.

2. Giải thích chi tiết Source Code

A. Chuẩn bị dữ liệu và Nhãn

Tập dữ liệu phổ biến nhất được sử dụng là CoNLL-2003, chứa các nhãn cho người (PER), tổ chức (ORG), địa điểm (LOC), và thực thể khác (MISC). Mã nguồn định nghĩa bảng ánh xạ label2id (ví dụ: B-PER: 1, I-PER: 2, O: 0). Tiền tố B- đánh dấu sự bắt đầu của một thực thể, và I- đánh dấu các từ tiếp theo thuộc cùng một thực thể đó.

B. Tokenization và Căn chỉnh nhãn (Alignment)

Đây là bước quan trọng nhất trong lập trình NER với BERT:

- Sub-word Tokenization: BERT sử dụng thuật toán WordPiece, có thể chia một từ thành nhiều mảnh (sub-tokens) (ví dụ: "Maarten" thành "Ma", "##arte", "##n")
- Aligning Labels: Vì nhãn gốc thường được gán cho cả từ, mã nguồn cần một hàm align_labels để gán nhãn cho tất cả các sub-tokens. Thông thường, sub-token đầu tiên nhận nhãn gốc (ví dụ: B-PER), các sub-tokens sau nhận nhãn I-PER hoặc nhãn đặc biệt -100 để bị bỏ qua khi tính toán hàm mất mát (loss function).

C. Khởi tạo mô hình

Sử dụng lớp AutoModelForTokenClassification từ thư viện transformers:

```
model = AutoModelForTokenClassification.from_pretrained(
```

```
"bert-base-cased",  
num_labels=len(id2label),  
id2label=id2label,  
label2id=label2id  
)
```

Việc khai báo `num_labels` giúp mô hình tự động tạo ra một lớp đầu ra (Linear layer) có kích thước phù hợp với số lượng thực thể cần nhận dạng.

D. Cấu hình huấn luyện và Đánh giá

Mô hình sử dụng `DataCollatorForTokenClassification`, khác với bài toán phân loại văn bản, collator này hỗ trợ padding cho cả chuỗi token và chuỗi nhãn tương ứng để đảm bảo các batch có cùng độ dài.

NER thường được đánh giá bằng F1-score (trung bình điều hòa của Precision và Recall). Mã nguồn sử dụng thư viện `seqeval` để tính toán F1 dựa trên thực thể hoàn chỉnh thay vì từng token riêng lẻ, vì việc chỉ nhận diện đúng một phần tên (ví dụ: chỉ "Marie" trong "Marie Curie") được coi là sai.

Đối tượng `Trainer` nhận vào các tham số như `learning_rate` (thường rất nhỏ, ví dụ: $2e-5$), `num_train_epochs`, và dữ liệu đã được tokenize để thực hiện vòng lặp huấn luyện.

E. Kiểm tra (Inference)

Sau khi huấn luyện, mô hình được đưa vào một pipeline để dự báo trên văn bản mới:

```
token_classifier = pipeline("token-classification", model="ner_model")  
  
token_classifier("My name is Maarten.")
```

Kết quả trả về sẽ bao gồm từng token, nhãn dự báo (ví dụ: B-PER), điểm tin cậy (score) và vị trí của chúng trong văn bản. Việc tinh chỉnh BERT cho NER tận dụng khả năng hiểu ngữ cảnh sâu sắc của mô hình pretrained để giải quyết sự mơ hồ về loại thực thể (ví dụ: "Washington" có thể là người hoặc địa điểm tùy vào ngữ

cảnh). Thành công của quá trình này phụ thuộc lớn vào việc căn chỉnh nhãn chính xác sau khi token hóa và sử dụng các độ đo đánh giá phù hợp ở cấp độ thực thể.

Bài tập 2. (tài liệu [2], [3])

Trình bày ứng dụng của NER trong bài toán Rút trích/Trích xuất thông tin (Information Extraction)

=====

Rút trích Thông tin (Information Extraction) là quá trình biến đổi dữ liệu văn bản phi cấu trúc thành các dạng dữ liệu có cấu trúc (như cơ sở dữ liệu quan hệ) để máy tính có thể xử lý sâu hơn. Trong sơ đồ phân cấp của IE, NER đóng vai trò là một nhiệm vụ nền tảng (foundation task) và là bước tiền xử lý quan trọng cho các nhiệm vụ phức tạp hơn.

Trong một quy trình IE tổng thể, NER cung cấp các thông tin để xây dựng nên các cấu trúc tri thức phức tạp hơn bằng cách xác định mối quan hệ giữa hai đối tượng (ví dụ: "Luca Maestri là Giám đốc tài chính của Apple"). Hệ thống trước hết phải nhận diện được "Luca Maestri" là một thực thể Người (PER) và "Apple" là một thực thể Tổ chức (ORG), nếu không có NER, RE không thể xác định được các đối tượng tham gia vào quan hệ.

Rút trích Sự kiện (Event Extraction) giúp nhận diện các chủ thể tham gia vào sự kiện (ai, ở đâu, khi nào). Ví dụ, trong một sự kiện về việc tăng giá vé máy bay, NER xác định các hãng hàng không và các mốc thời gian liên quan. Sau đó sẽ tìm kiếm các tình huống điển hình trong văn bản và điền thông tin vào các vị trí (slots) trống. NER cung cấp các giá trị để điền vào các slot này, chẳng hạn như tên công ty, ngày tháng, hoặc vị trí địa lý.

NER không chỉ dừng lại ở việc gán nhãn loại thực thể (như PER, LOC, ORG) mà còn là bước đầu của Liên kết Thực thể (Entity Linking - NEL). NER tìm ra các đoạn văn bản là tên riêng, sau đó NEL sẽ ánh xạ chúng tới một định danh duy nhất trong một ontology.

Ví dụ: Phân biệt "Washington" là một tiểu bang, một thành phố, hay tên một tổng thống.

Các thông tin rút trích được qua NER và NEL sẽ được tổ chức dưới dạng các bộ ba (triples) như <chủ thể, quan hệ, đối tượng> để xây dựng các biểu đồ tri thức lớn (ví dụ: Google Knowledge Graph), phục vụ cho tìm kiếm và trả lời câu hỏi.