

Chiến lược chọn số cụm k trong K-means

1. Elbow Method (Phương pháp khuỷu tay) — phổ biến nhất

Ý tưởng:

- Chạy K-means với nhiều giá trị k: $1 \rightarrow 10$ (hoặc 15).
- Tính tổng bình phương khoảng cách trong cụm (WCSS – Within-Cluster Sum of Squares).
- Vẽ đồ thị WCSS theo k.
- Điểm “khuỷu tay” (chỗ bắt đầu giảm chậm lại) $\rightarrow$ k tối ưu.

Khi dùng:

- Dữ liệu có phân cụm tương đối rõ.
- Dễ triển khai, dễ giải thích.

2. Silhouette Score (Hệ số silhouette)

Ý tưởng:

- Đánh giá mức độ **chặt chẽ trong cụm** và **tách biệt giữa các cụm**.
- Silhouette Score $\in [-1, 1]$:

Giá trị	Ý nghĩa
~ 1	Các cụm rất rõ ràng
~ 0	Cụm chồng chéo nhau
< 0	Phân cụm rất tệ

Cách chọn k:

- Chạy K-means với nhiều k.
- Chọn k có **silhouette cao nhất**.

Khi dùng:

- Khi bạn muốn một thước đo định lượng, khách quan, chính xác hơn Elbow.

3. Gap Statistic (Thống kê khoảng cách)

Ý tưởng:

- So sánh WCSS thực tế với WCSS của dữ liệu **ngẫu nhiên**.
- Chọn k lớn nhất sao cho:

$$\text{Gap}(k) \geq \text{Gap}(k+1) - s(k+1)$$

→ Tương đương nói rằng thêm cụm không mang lại nhiều cải thiện nữa.

Khi dùng:

- Khi muốn phương pháp khoa học, ổn định hơn Elbow.
- Nhưng tính toán hơi tốn thời gian.

4. Calinski–Harabasz Index

Ý tưởng:

- Tỷ lệ giữa:
 - độ phân tán giữa các cụm (cao)
 - độ phân tán trong cụm (thấp)

→ Chọn k cho giá trị cao nhất.

Khi dùng:

- Khi dữ liệu có phân tán tuyến tính tốt.

5. Davies–Bouldin Index

Ý tưởng:

- Đo độ tương đồng giữa các cụm (thấp là tốt).
- Chọn k cho giá trị **nhỏ nhất**.

Khi dùng:

- Khi muốn đánh giá theo độ tương đồng cụm.

6. Rule of Thumb (Luật ngón tay cái)

Một số quy tắc kinh nghiệm:

- $k \approx \sqrt{(n / 2)}$

- n = số điểm dữ liệu
- Áp dụng khi dữ liệu lớn mà không biết cách dùng các phương pháp trên.

- **Dựa trên kiến thức lĩnh vực (domain knowledge)**

Ví dụ:

- Phân nhóm khách hàng (3–5 nhóm)
- Nhóm rủi ro tài chính (khoảng 2–4 nhóm)
- Nhóm hoa Iris (3 loài $\rightarrow k=3$)

7. Dendrogram (từ phân cụm phân cấp)

Dù K-means không dùng phân cấp, nhưng ta có thể:

- Dùng hierarchical clustering $\rightarrow$ vẽ dendrogram.
- Nhìn số nhánh cắt $\rightarrow$ đề xuất k hợp lý cho K-means.

8. PCA Scatter Plot (quan sát dạng hình học)

Vẽ dữ liệu ra PCA 2D/3D $\rightarrow$ nhìn xem có bao nhiêu cụm rõ ràng.

Áp dụng tốt khi:

- Dữ liệu ít chiều
- Cụm có hình dạng tương đối tròn

9. Tóm tắt nhanh

Phương pháp	Ưu điểm	Nhược điểm
Elbow	đơn giản	mang tính cảm tính
Silhouette	chính xác, định lượng	tính cho từng điểm, hơi chậm
Gap Statistic	khoa học, ổn định	tính toán nặng
Calinski–Harabasz	nhanh	k lớn thường được ưu tiên
Davies–Bouldin	tốt cho dữ liệu không tròn	dễ bị nhiễu
Domain knowledge	thực tế nhất	phụ thuộc chuyên gia